Gate付き Retrieval-Augmented Forecasting による突発需要の予測

TCU_mlab

奈良原俊誠　斎藤陽　橋本朋樹

宇治雅貴　白川滉　栗山翔伍　村山大成

1. 背景　書籍・雑誌市場の制度

再販売価格維持制度

定価販売が一般的

→ 価格競争を抑制

↓

マイナー書籍が存続

↓

◆多品種少数生産

委託販売制度

多品種少数生産＋限られた在庫

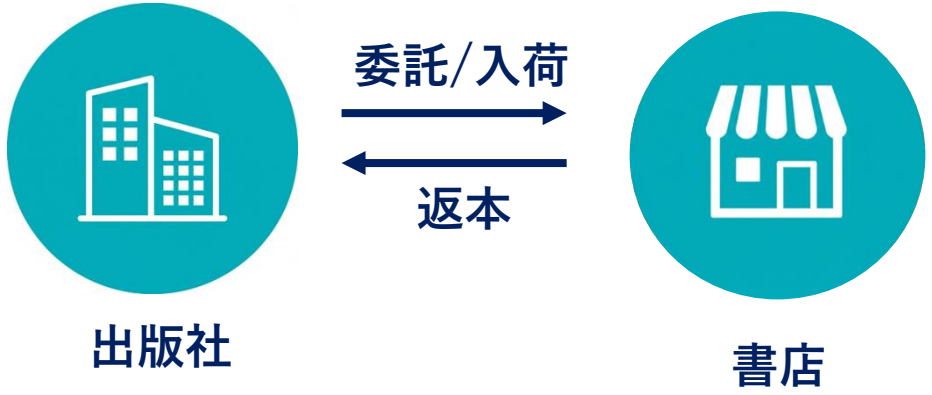

返本制度

1. 背景　制度による問題

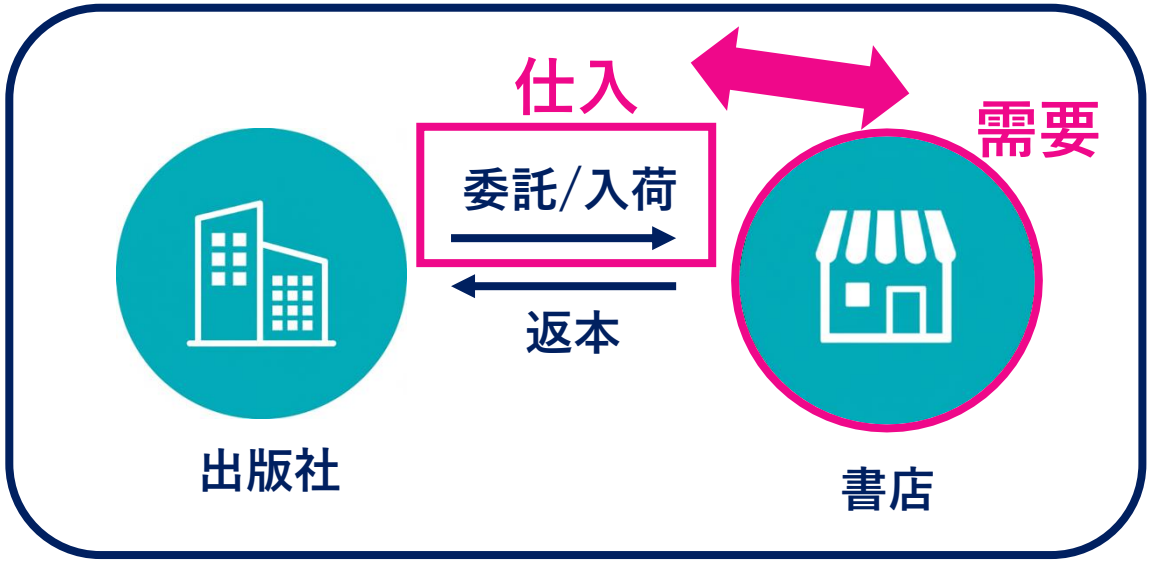

仕入と需要の誤差

↓

出版社の返本対応

送料　　キャッシュフローの悪化

49.7%

書籍・雑誌の返本率の推移

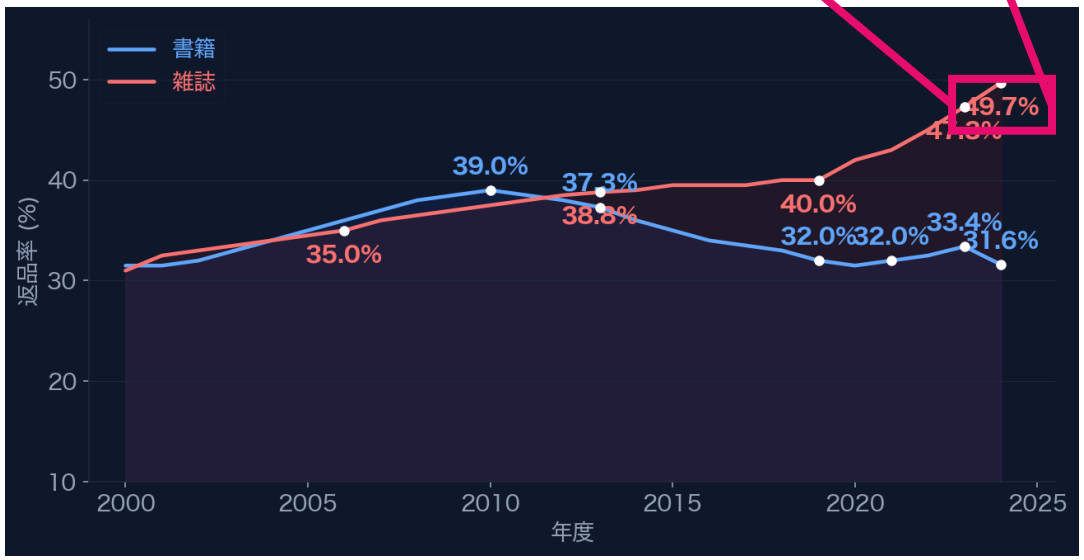

出典：出版科学研究所「出版指標年報」等

1. 背景　制度による問題

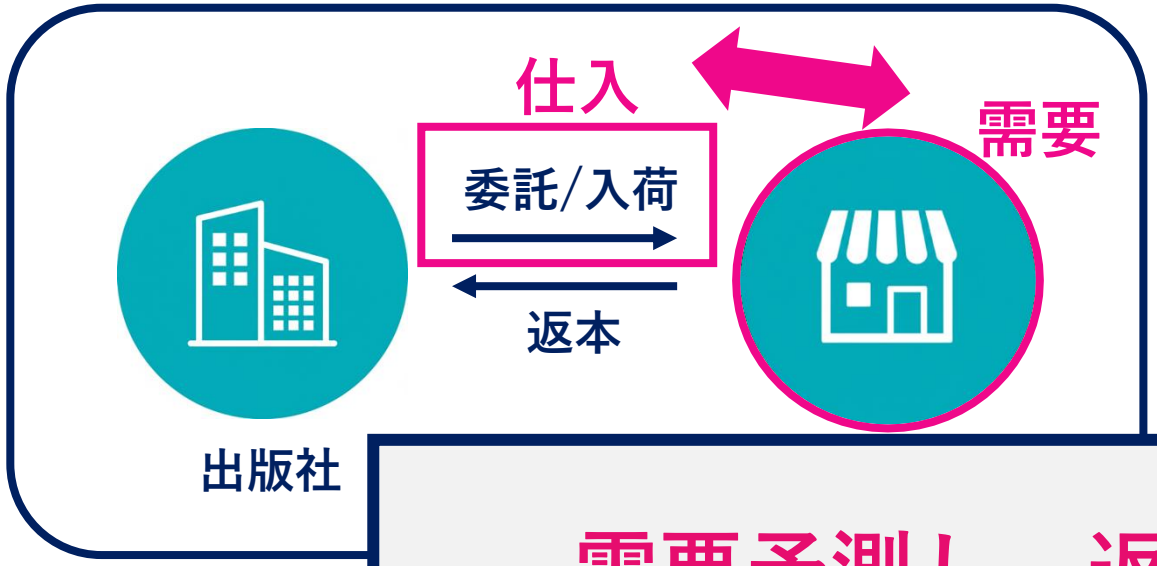

需要予測し，返本をなくしたい

仕入

↓

出版社の返本対応

- 送料
- キャッシュフローの悪化

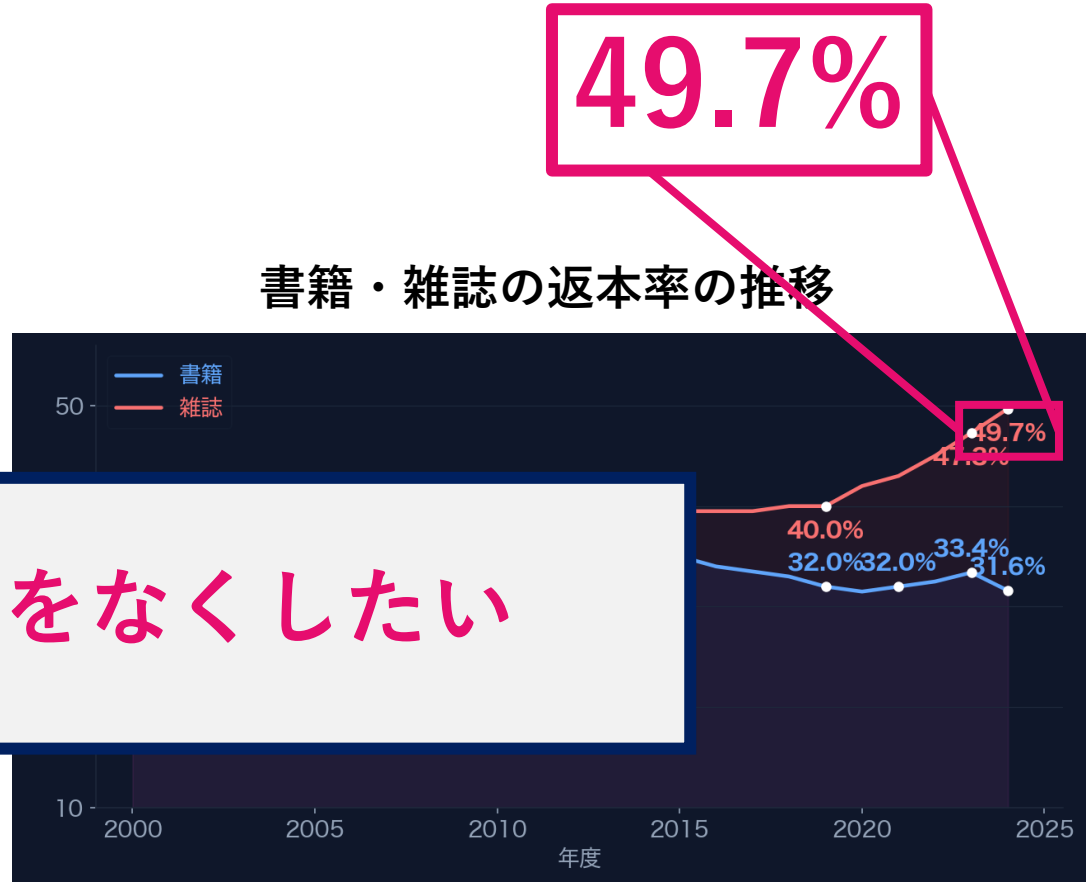

出典：出版科学研究所「出版指標年報」等

1. 背景　書籍・雑誌の需要予測

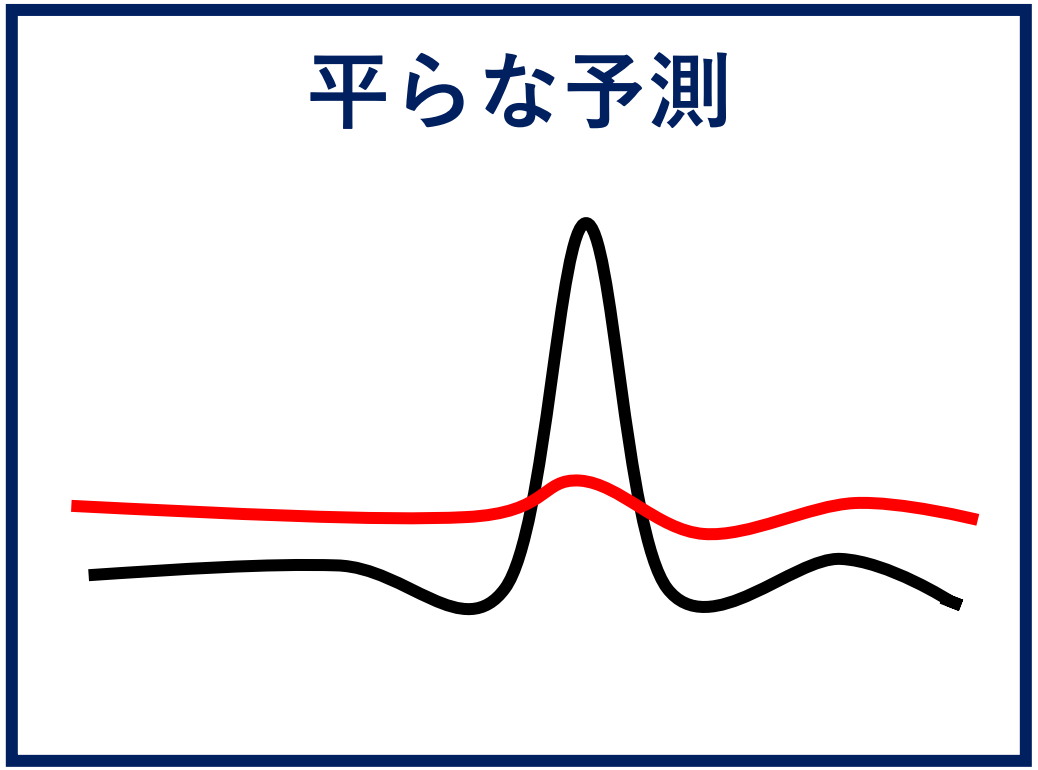

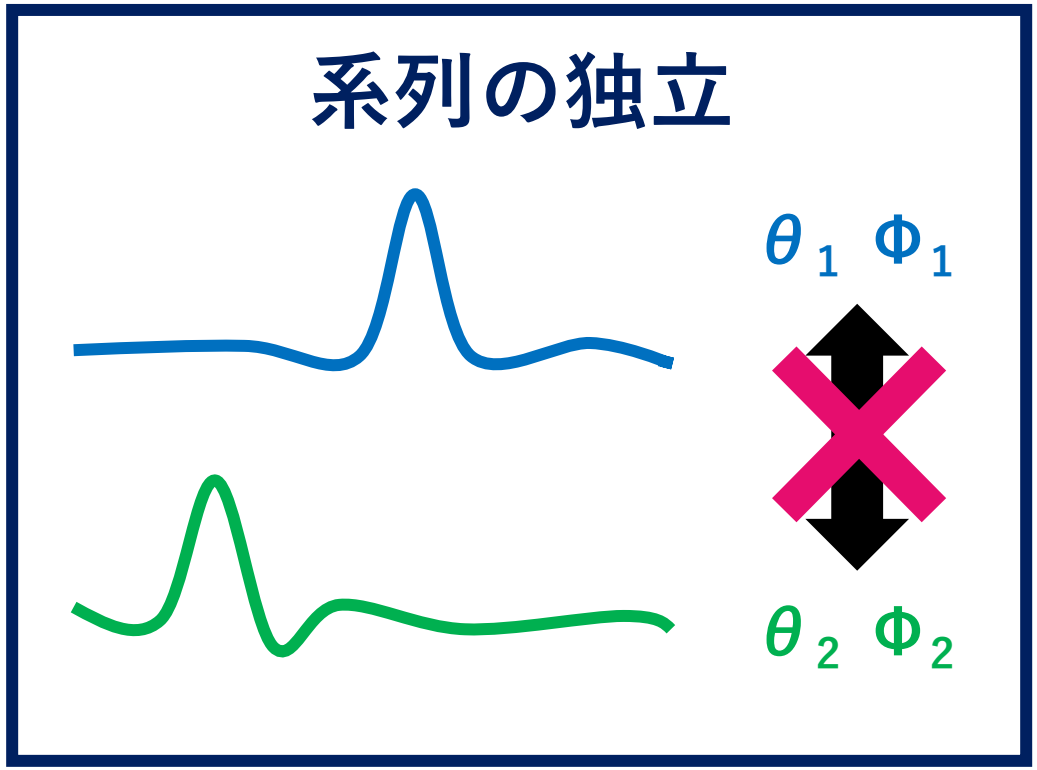

多品種少数生産+誤差全体の最小化

↳ スパイクの無視

系列ごとに独立したパラメータ

↳ 少数のスパイクデータの学習不足

1. 背景　書籍・雑誌の需要予測

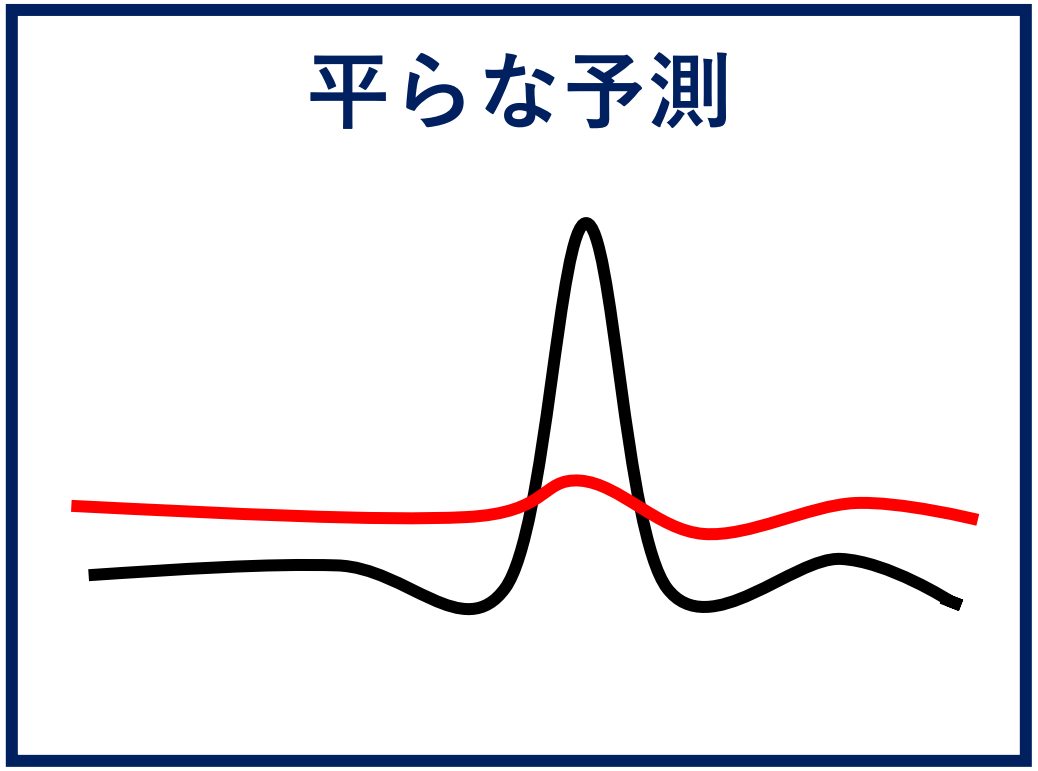

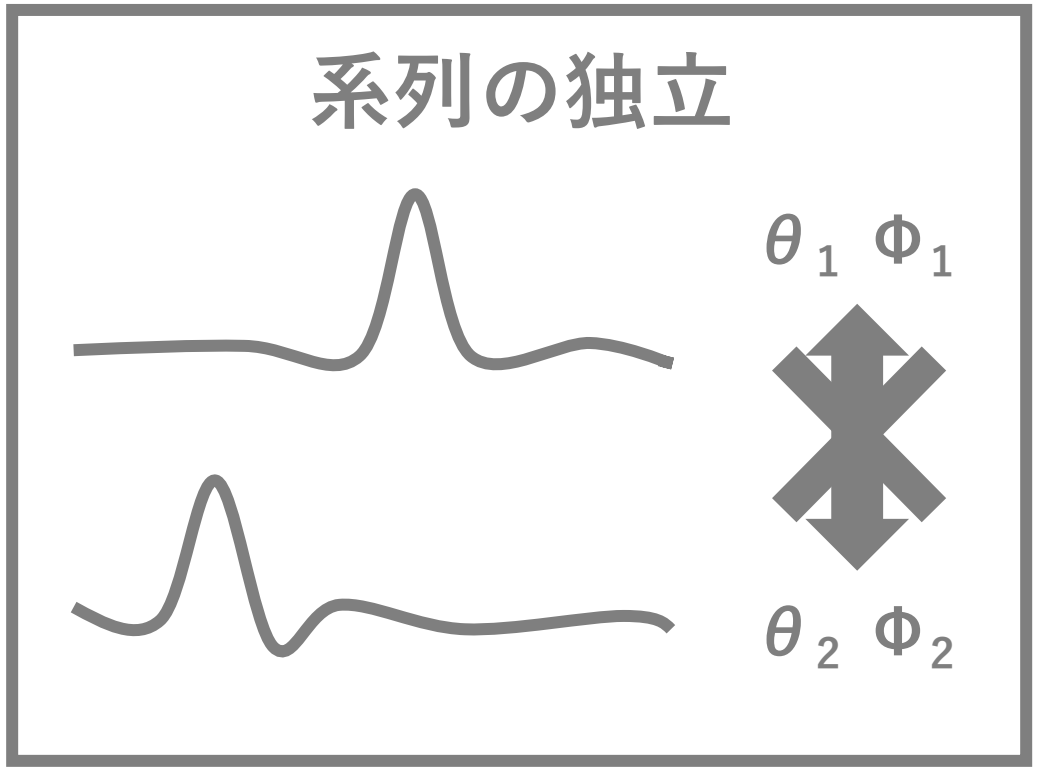

多品種少数生産+誤差全体の最小化

↳ スパイクの無視

系列ごとに独立したパラメータ

↳ 少数のスパイクデータの学習不足

1. 背景　書籍・雑誌の需要予測

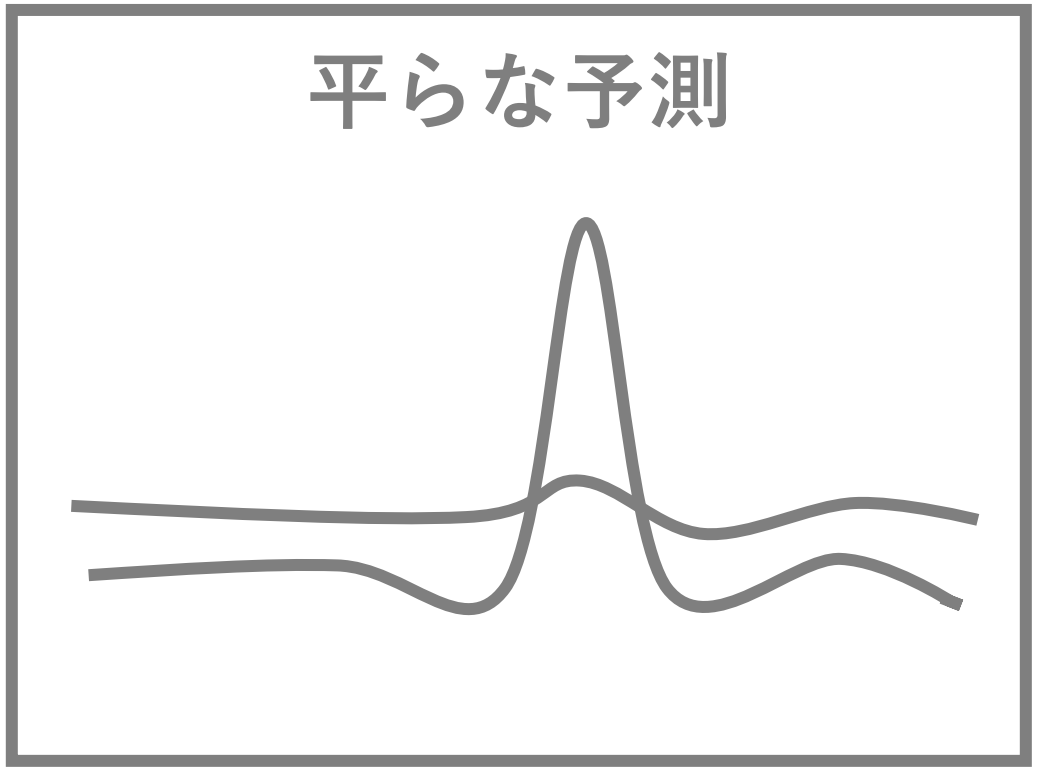

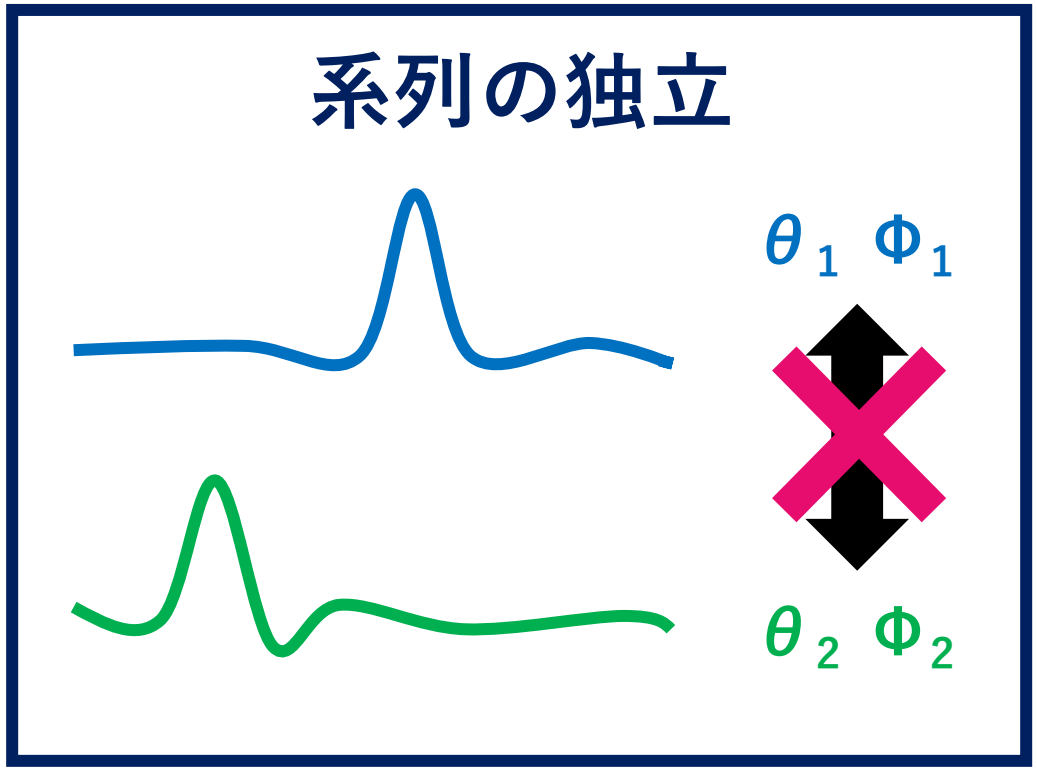

多品種少数生産+誤差全体の最小化

↳ スパイクの無視

系列ごとに独立したパラメータ

↳ 少数のスパイクデータの学習不足

1. 背景　書籍・雑誌の需要予測

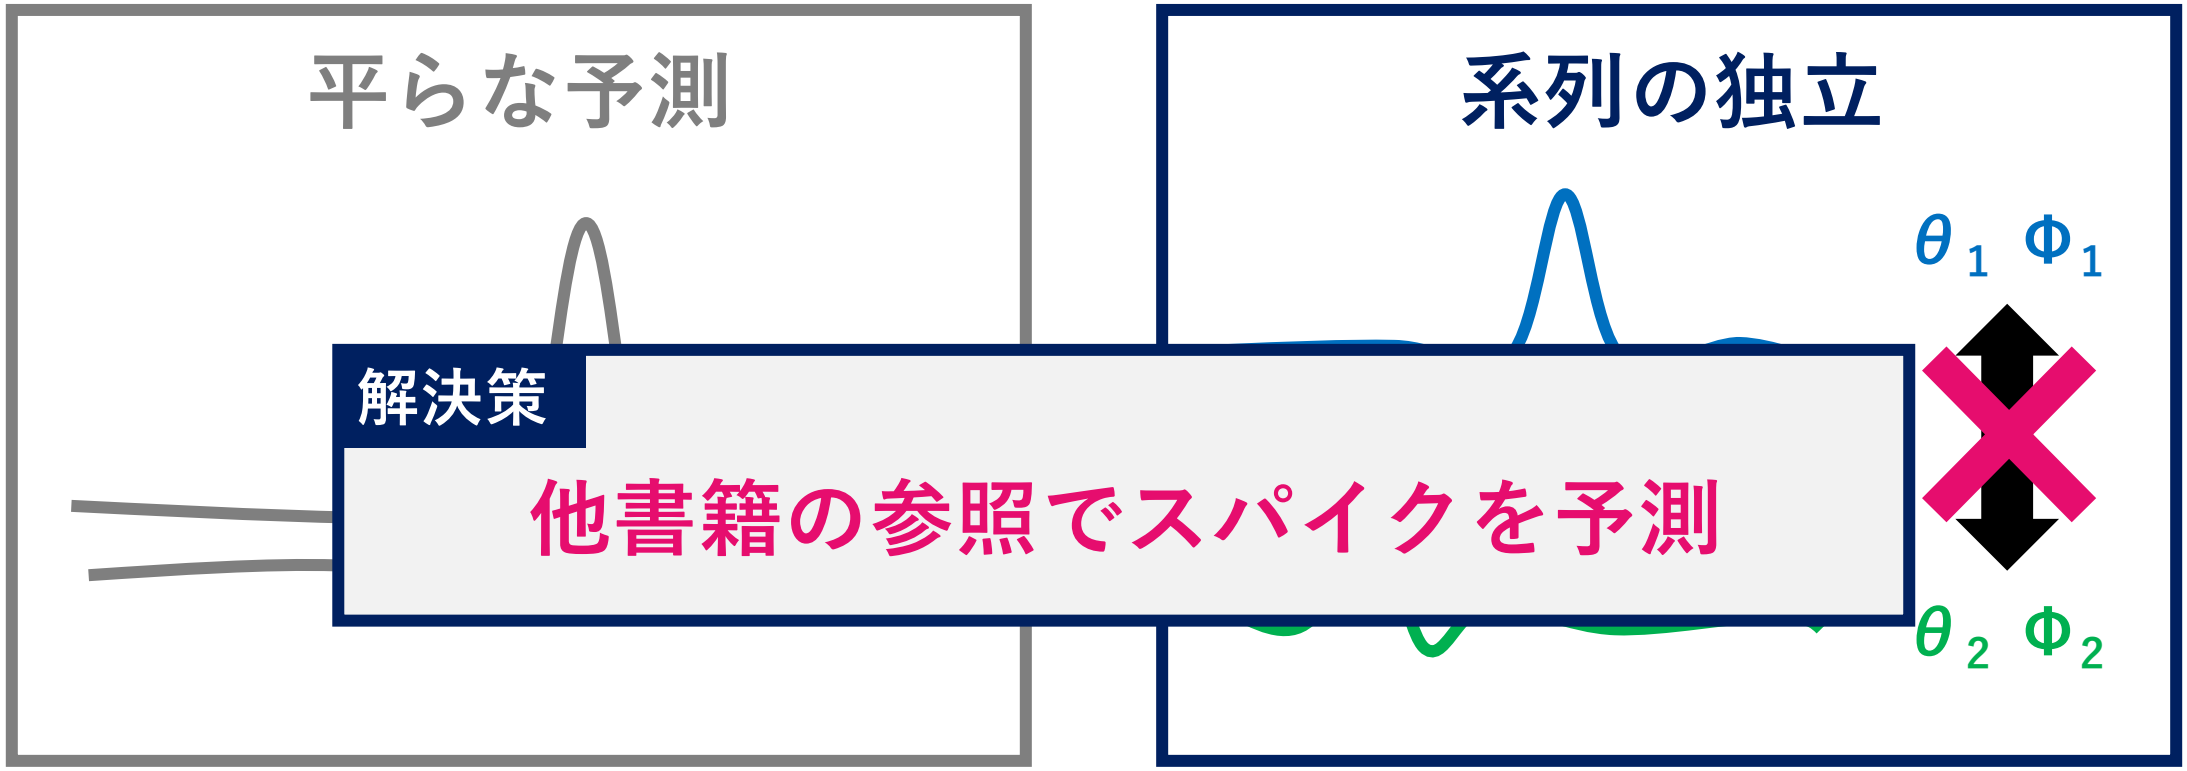

多品種少数生産+誤差全体の最小化

↳ スパイクの無視

系列ごとに独立したパラメータ

↳ 少数のスパイクデータの学習不足

1. 背景　RAFとは

RAF : Retrieval-Augmented Forecasting

RAF

外部データの参照で時系列予測を向上

❶検索　似た外部データを検索

❷拡張　検索したデータを入力に追加

❸予測　拡張したデータで予測

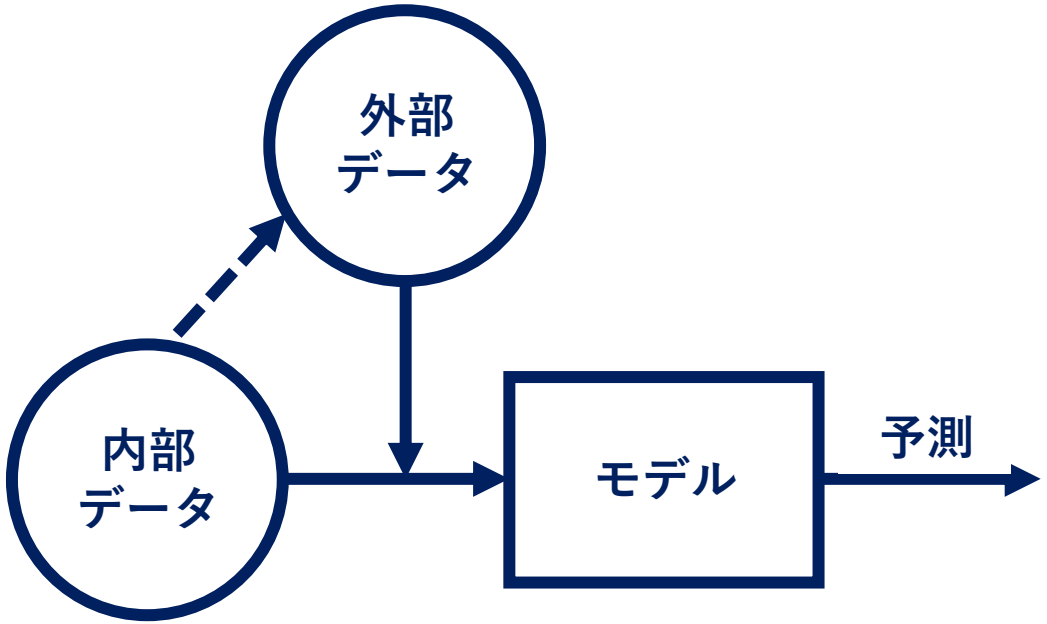

1. 背景　RAFとは

RAF : Retrieval-Augmented Forecasting

RAF

外部データの参照で時系列予測を向上

❶検索　似た外部データを検索

❷拡張　検索したデータを入力に追加

❸予測　拡張したデータで予測

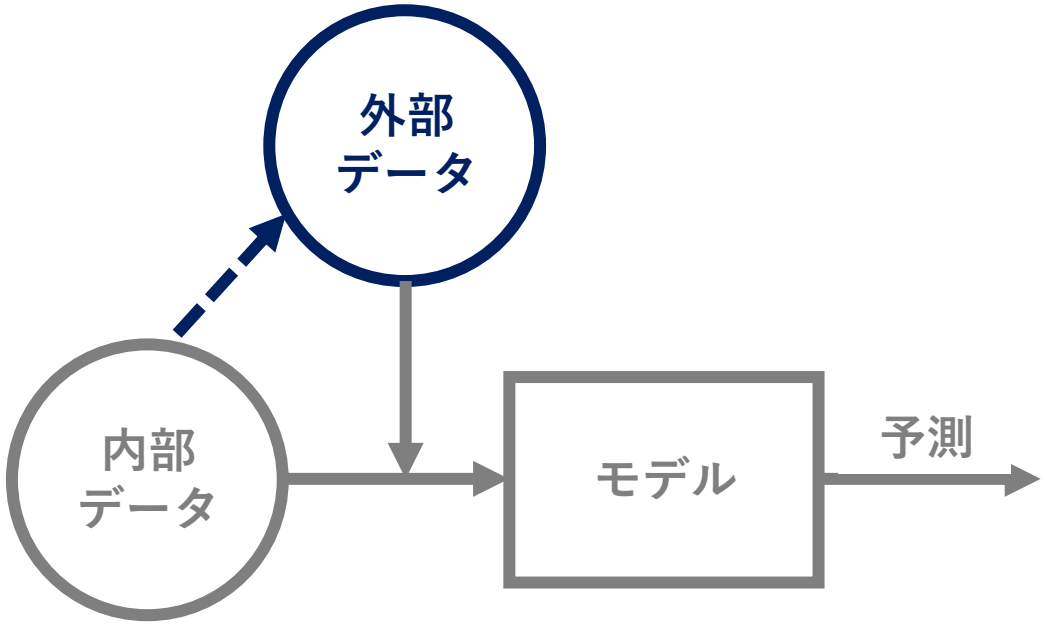

1. 背景　RAFとは

RAF : Retrieval-Augmented Forecasting

RAF

外部データの参照で時系列予測を向上

❶検索　似た外部データを検索

❷拡張　検索したデータを入力に追加

❸予測　拡張したデータで予測

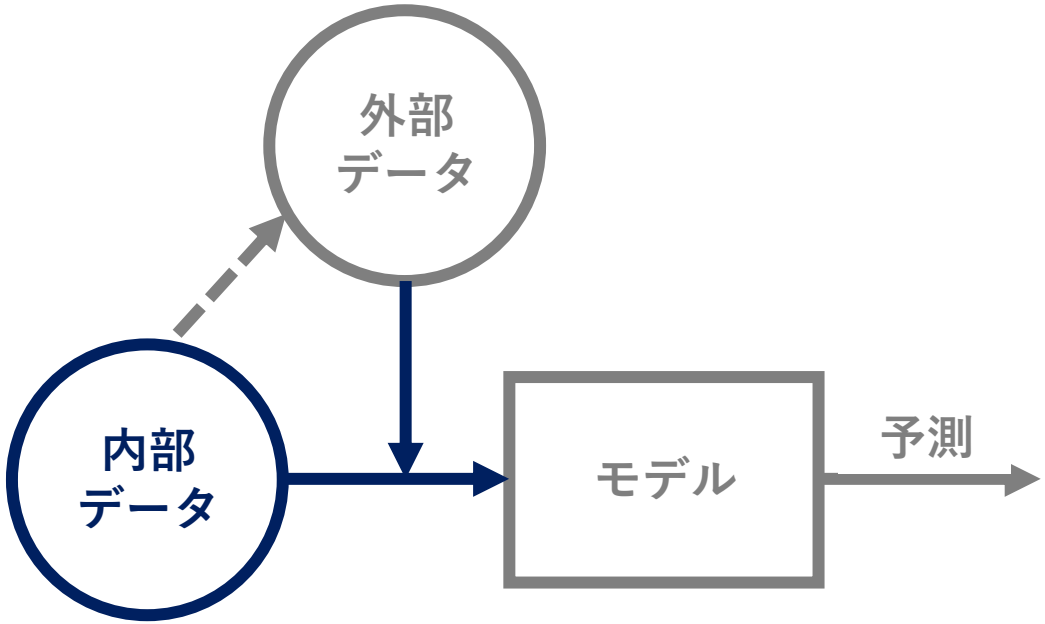

1. 背景　RAFとは

RAF : Retrieval-Augmented Forecasting

RAF

外部データの参照で時系列予測を向上

❶検索　似た外部データを検索

❷拡張　検索したデータを入力に追加

❸予測　拡張したデータで予測

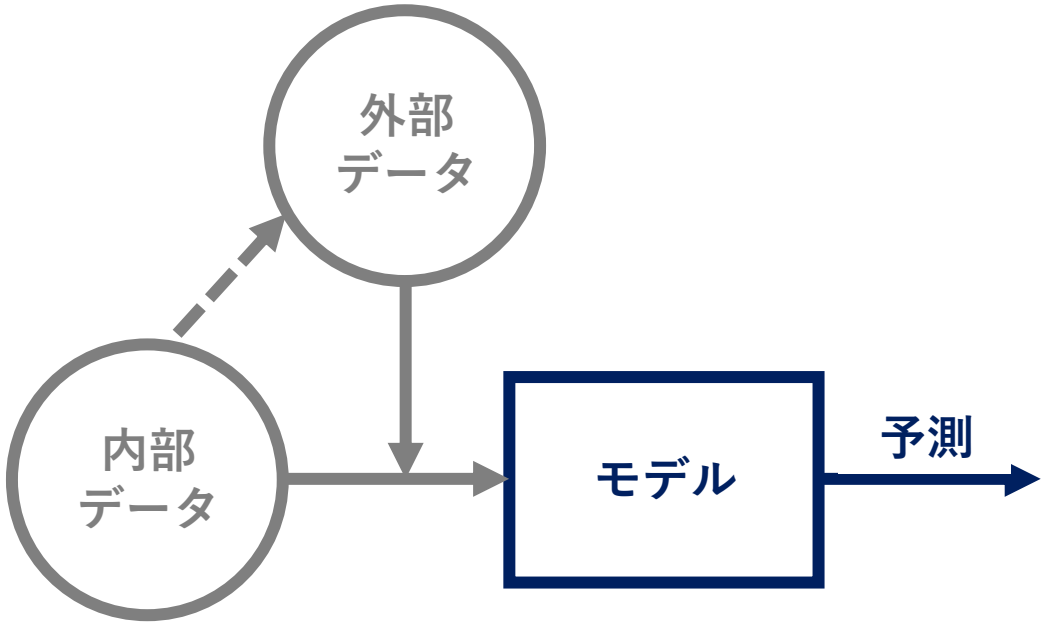

1. 背景　RAFとは

RAF : Retrieval-Augmented Forecasting

RAF

外部データの参照で時系列予測を向上

❶検索

RAFによる他書籍の参照

❷拡張

検索したデータを

❸予測

拡張し

スパイク予測を向上

モデル

予測

2. 研究目的

在庫変動は“スパイクの有無”に大きく影響される…

目的

多品種少数生産における“スパイク”の予測

提案手法

Step1 RAFによる他系列の参照

データポイントの少ないスパイクを予測

＋

RAF:Retrieval-Augmented Forecasting

Step2 Gateによる参照の選別

不要な参照を防止

3. 提案手法

Step1 RAFによる他系列の参照

需要予測にRAFを使用

- 結合による時系列の不連続
- 検索データの強制採用

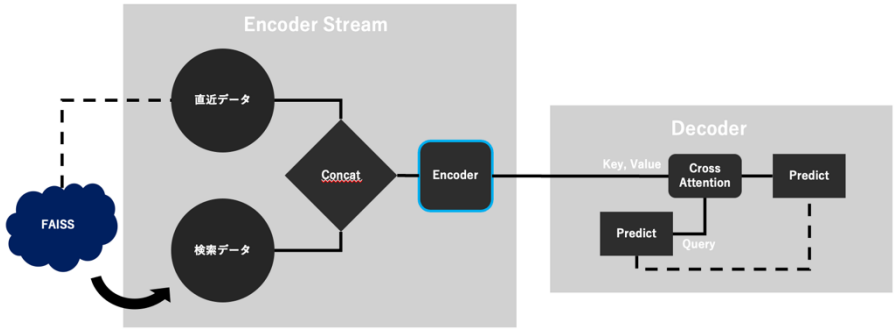

RAFアーキテクチャ

Step2 Gateによる参照の選別

RAFの問題点を解決

Multi-Stream + Gate

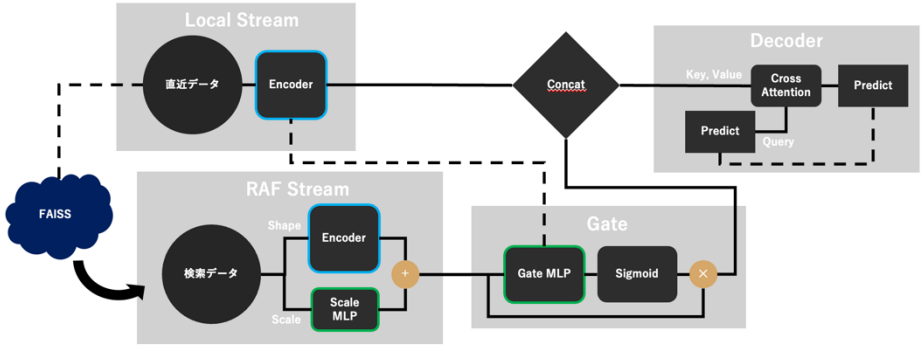

Gate-RAFアーキテクチャ

3. 提案手法

Step1 RAFによる他系列の参照

需要予測にRAFを使用

- 結合による時系列の不連続
- 検索データの強制採用

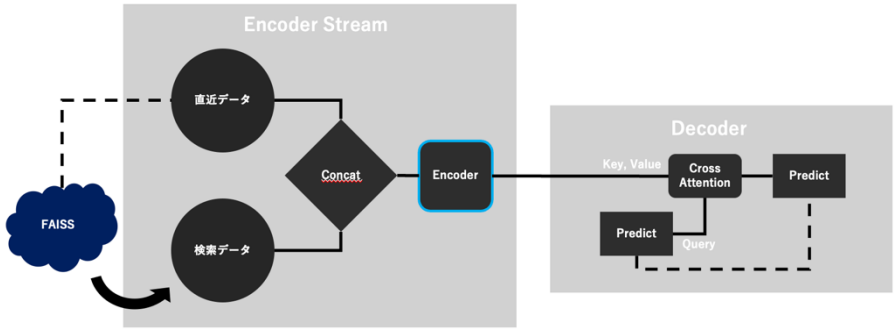

RAFアーキテクチャ

Step2 Gateによる参照の選別

RAFの問題点を解決

Multi-Stream + Gate

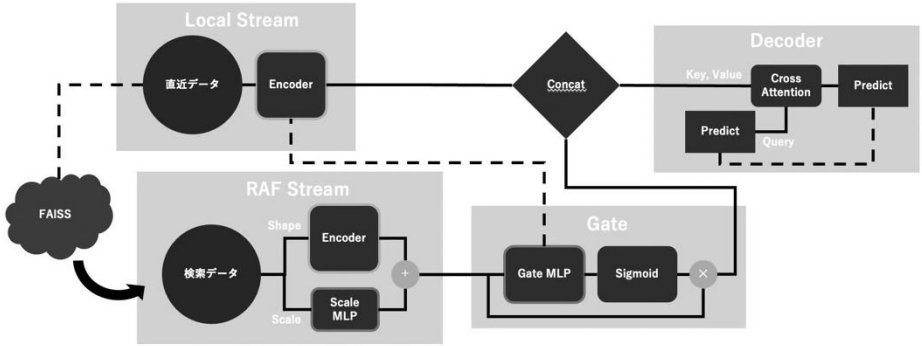

Gate-RAFアーキテクチャ

3. 提案手法

Step1 RAFによる他系列の参照

需要予測にRAFを使用

- 結合による時系列の不連続
- 検索データの強制採用

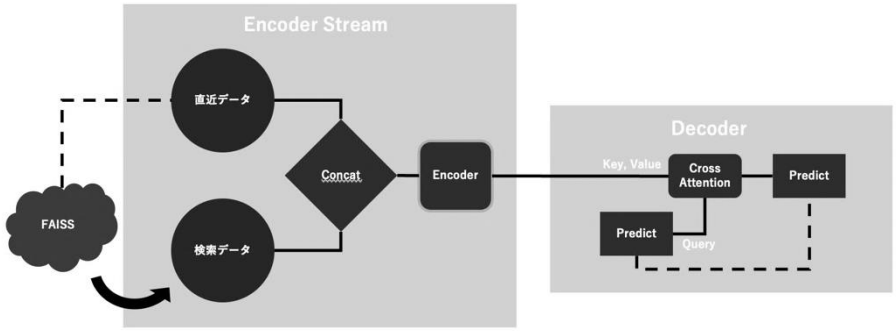

RAFアーキテクチャ

Step2 Gateによる参照の選別

RAFの問題点を解決

Multi-Stream + Gate

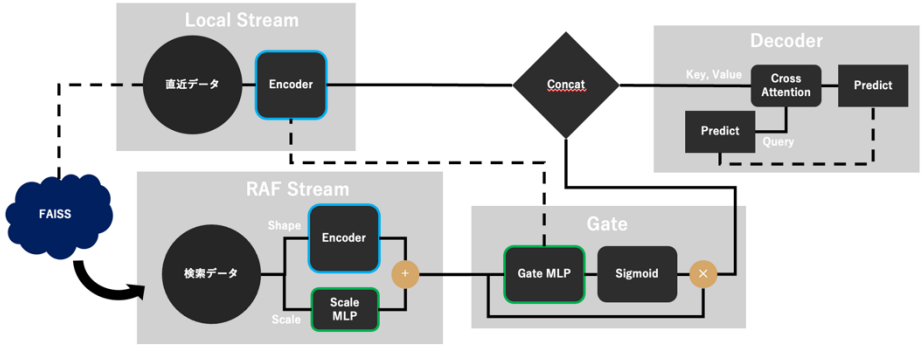

Gate付きRAFアーキテクチャ

3. 提案手法　RAFアーキテクチャ

Step1　RAFによる他系列の参照

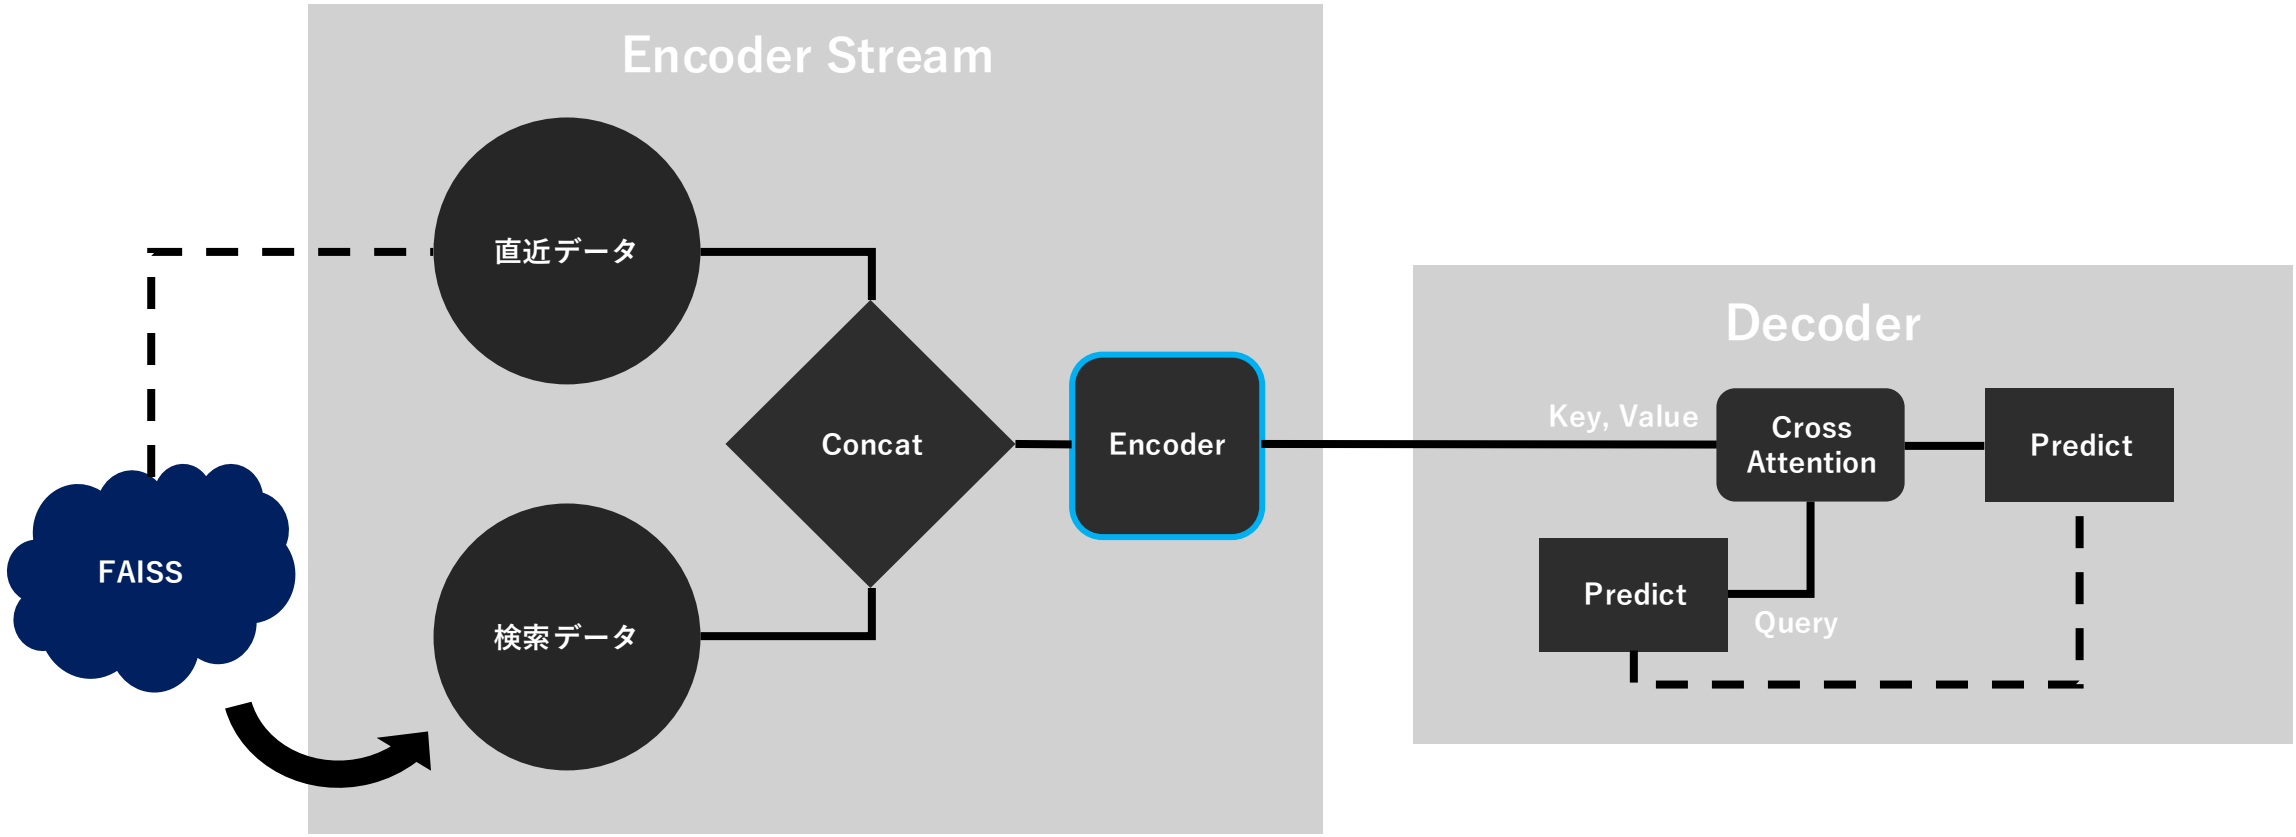

3. 提案手法　RAFアーキテクチャ

Step1　RAFによる他系列の参照

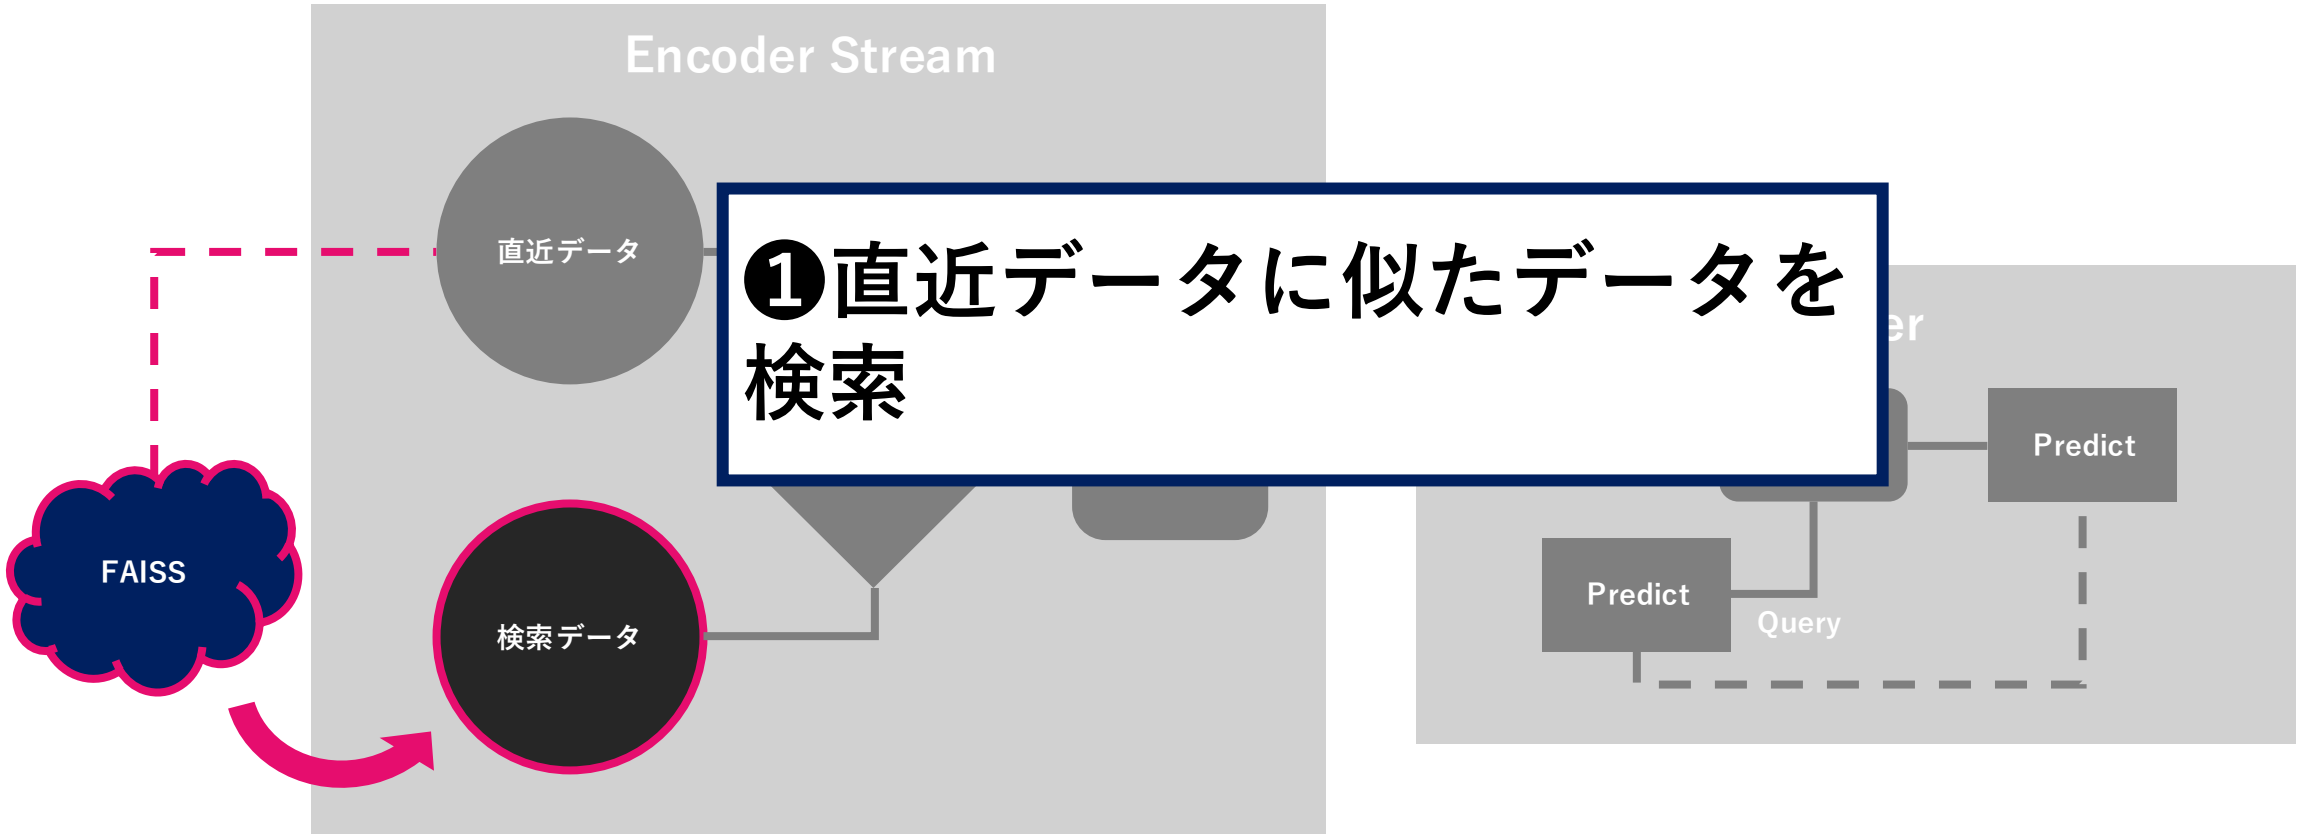

❶直近データに似たデータを検索

3. 提案手法　RAFアーキテクチャ

Step1　RAFによる他系列の参照

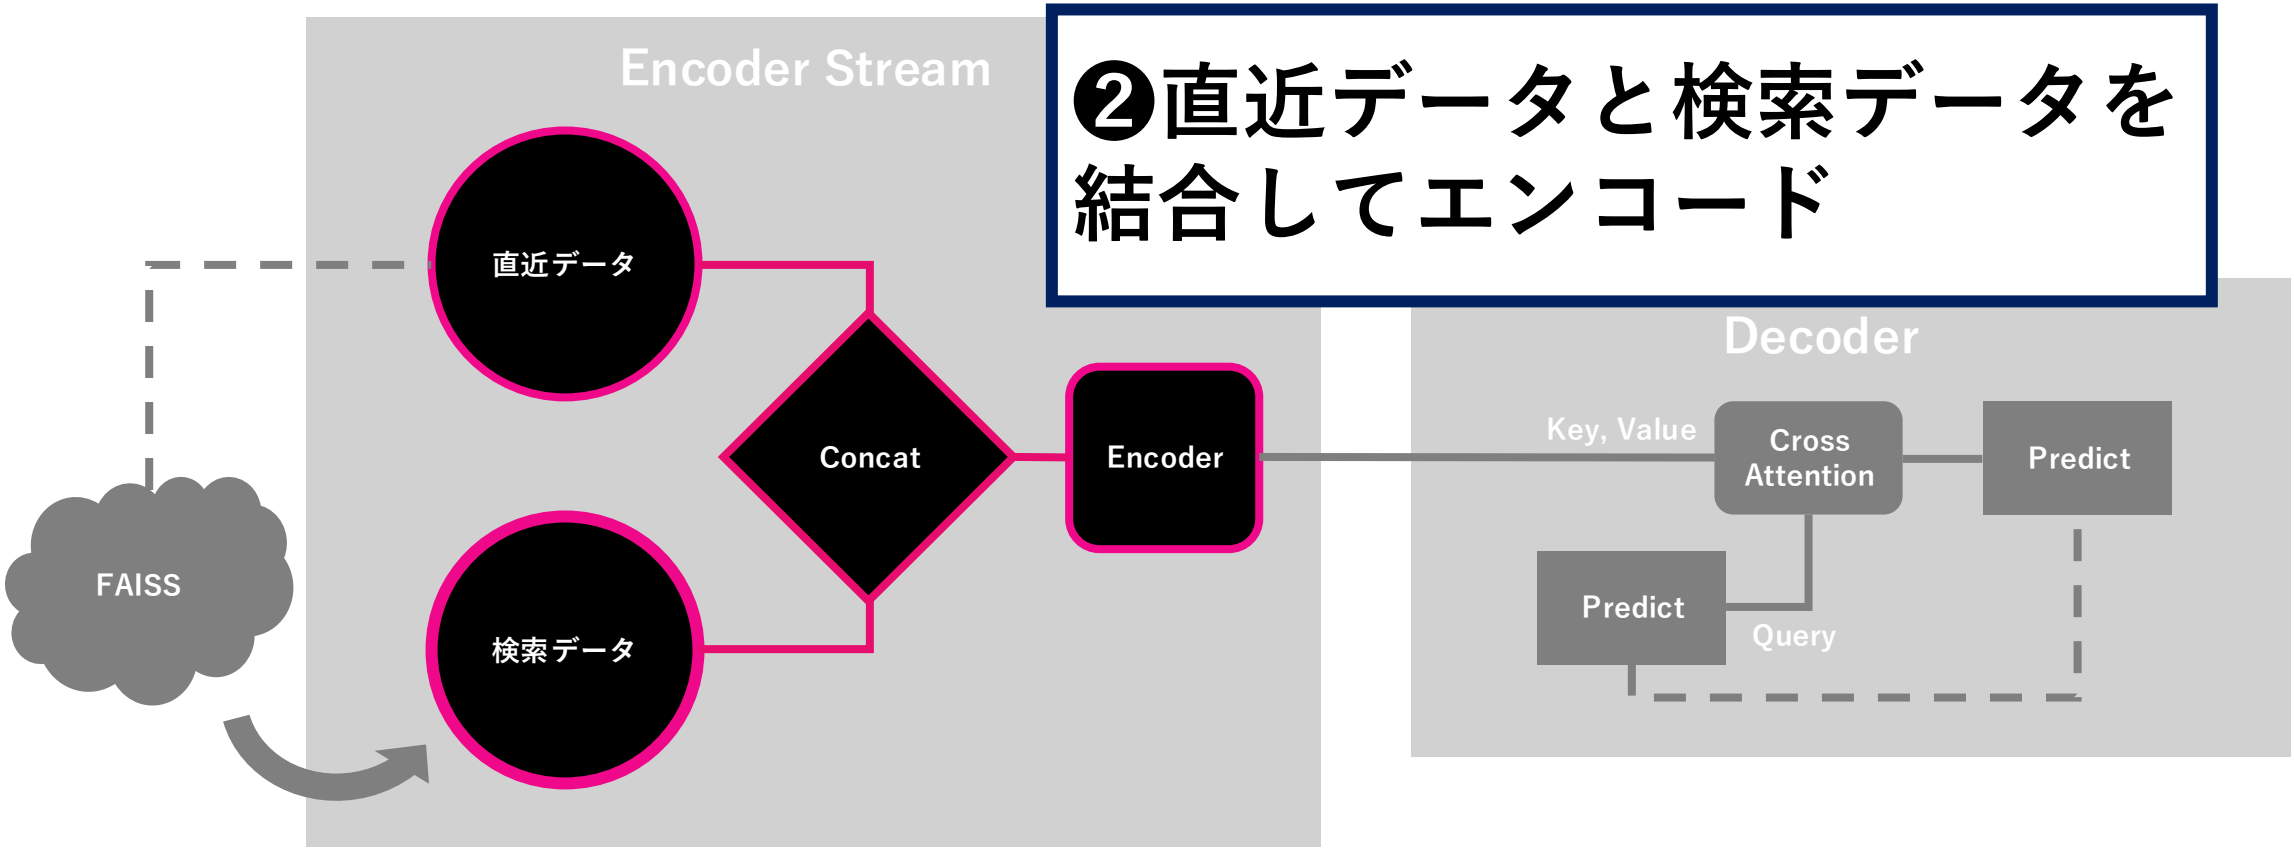

❷直近データと検索データを結合してエンコード

3. 提案手法　RAFアーキテクチャ

Step1　RAFによる他系列の参照

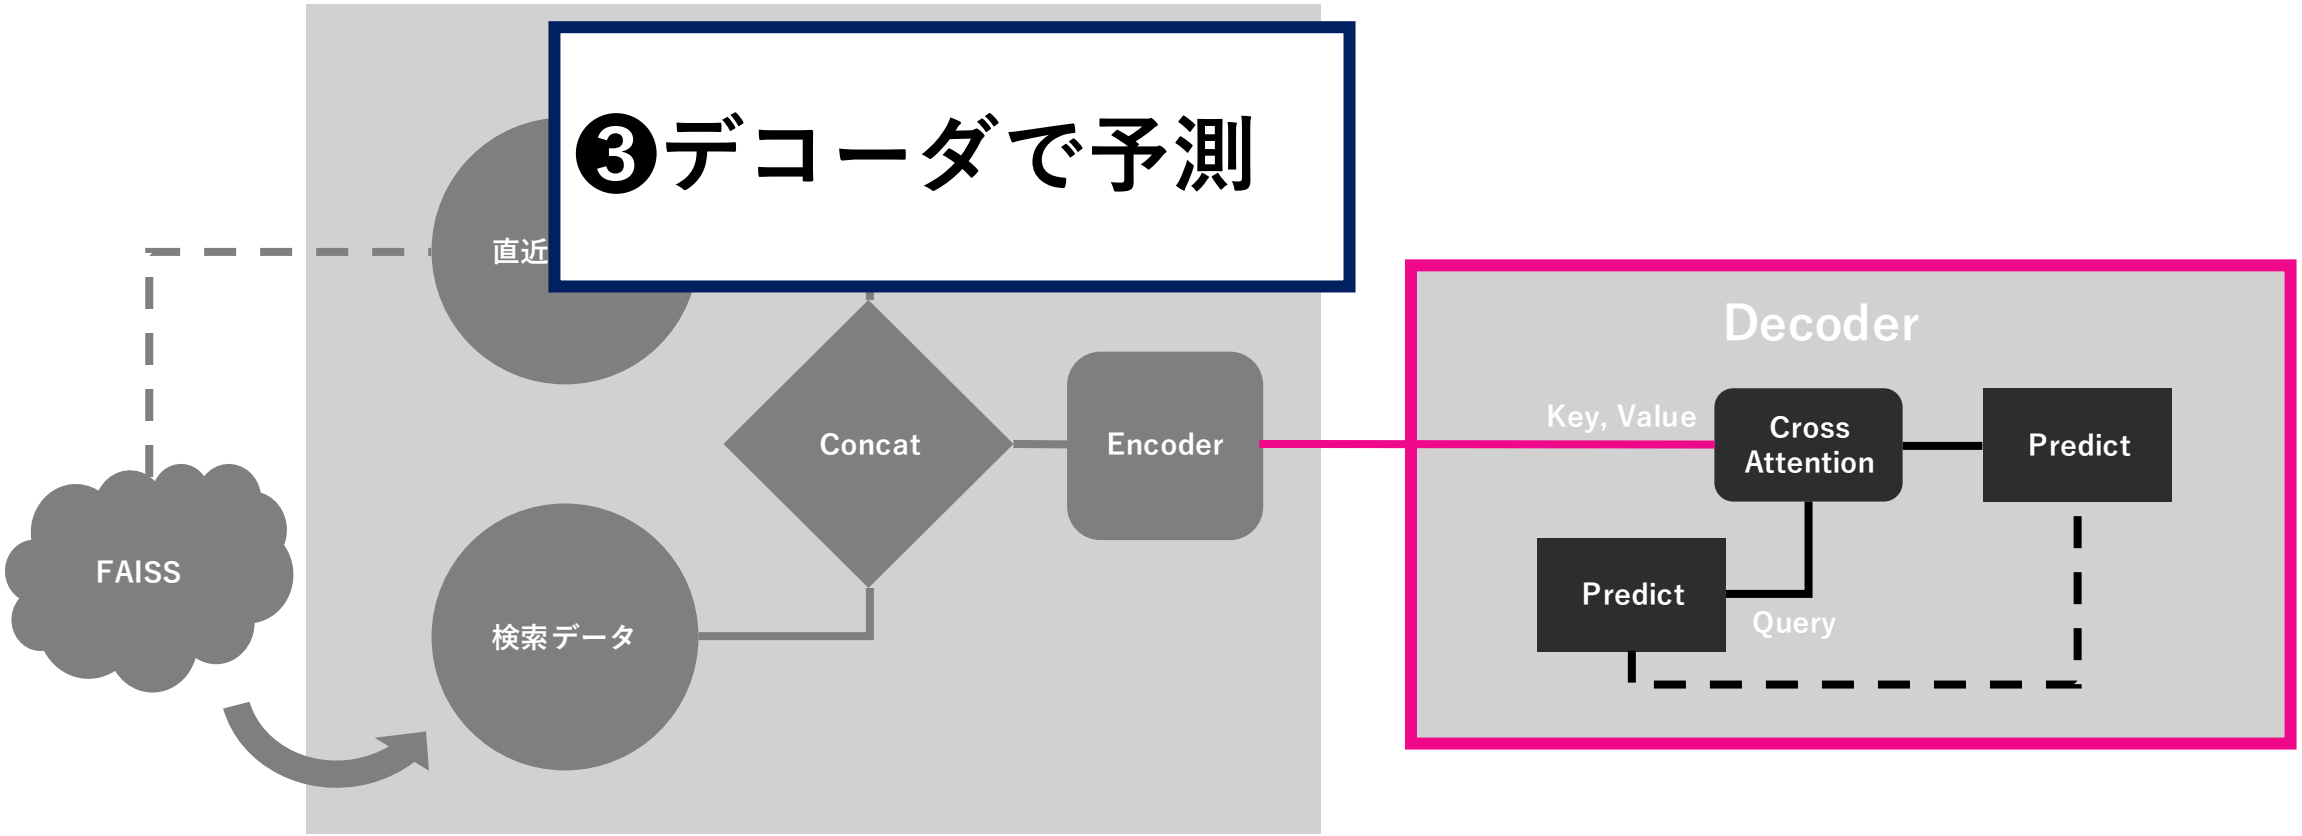

3. 提案手法　RAFアーキテクチャ

Step1　RAFによる他系列の参照

結合による時系列の不連続

直近・検索データで時間が連続しない

直近データ　3/4　6/4 → ?　検索データ　1/7　4/7

検索データの強制採用

似ていないデータも使用してしまう

直近データ → 検索データ ? ?

RAFの“改良点”

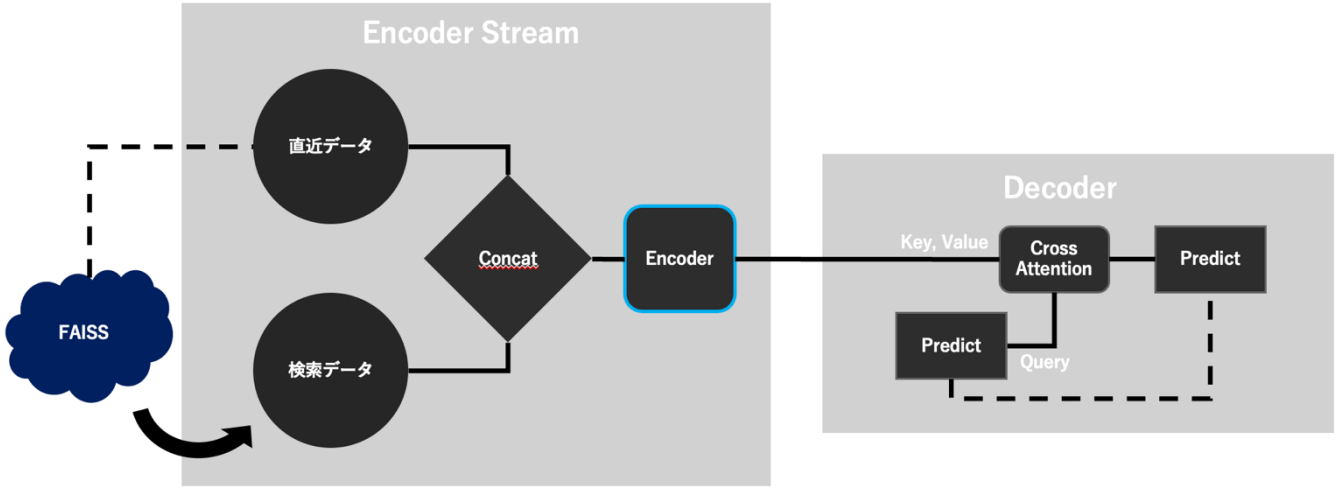

3. 提案手法　RAFアーキテクチャ

Step1　RAFによる他系列の参照

結合による時系列の不連続

直近・検索データで時間が連続しない

直近データ　3/4　6/4 → ?　検索データ　1/7　4/7

検索データの強制採用

似ていないデータも使用してしまう

直近データ → 検索データ

RAFの“改良点”

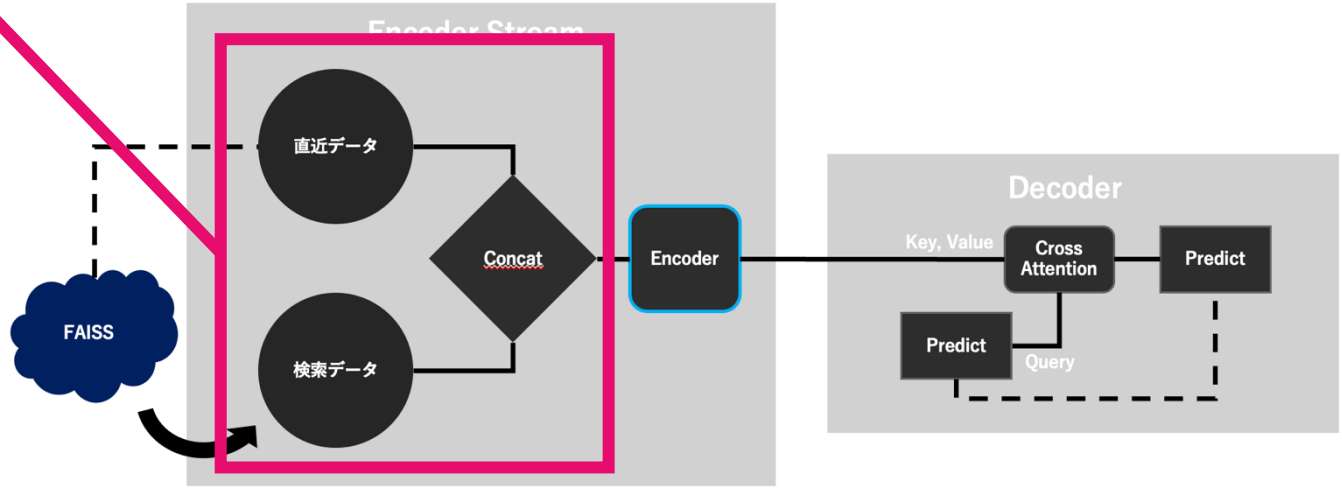

3. 提案手法　RAFアーキテクチャ

Step1　RAFによる他系列の参照

RAFの“改良点”

結合による時系列の不連続

直近・検索データで時間が連続しない

直近データ　3/4　6/4 → ?　検索データ　1/7　4/7

検索データの強制採用

似ていないデータも使用してしまう

直近データ → 検索データ

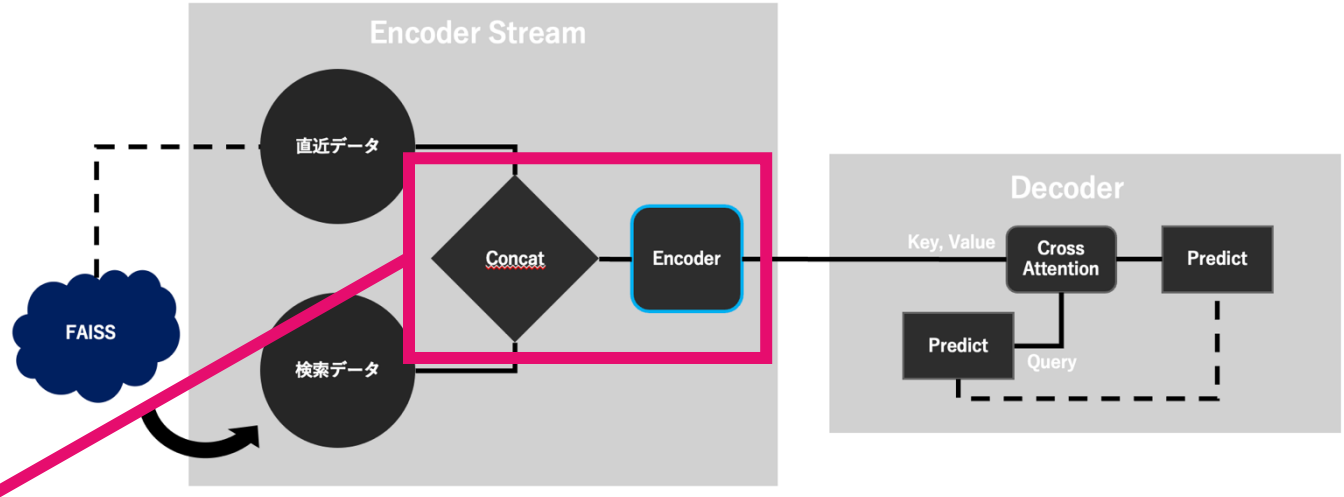

3. 提案手法　RAFアーキテクチャ

Step2　Gateによる参照の選別

結合による時系列の不連続

直近・検索データで時間が連続しない

検索データの強制採用

似ていないデータも使用してしまう

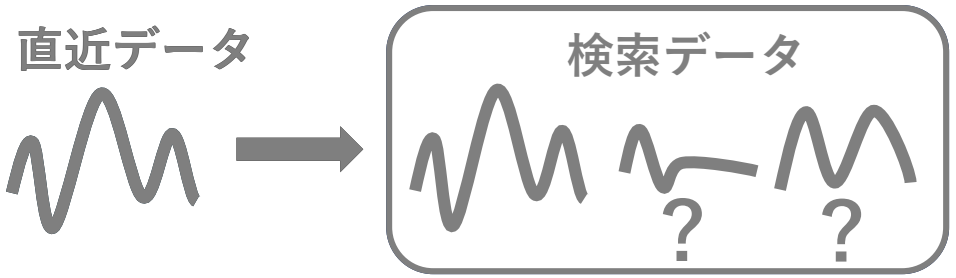

RAFの“改良点”

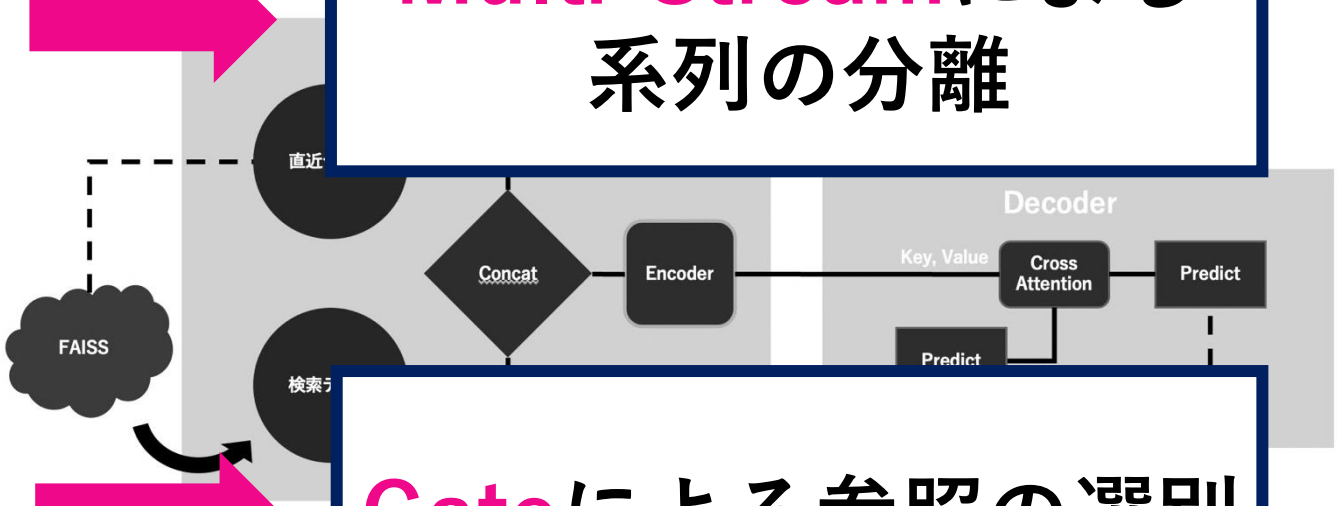

Multi-Streamによる系列の分離

Gateによる参照の選別

3. 提案手法　Gate付きRAFアーキテクチャ

Step2　Gateによる参照の選別

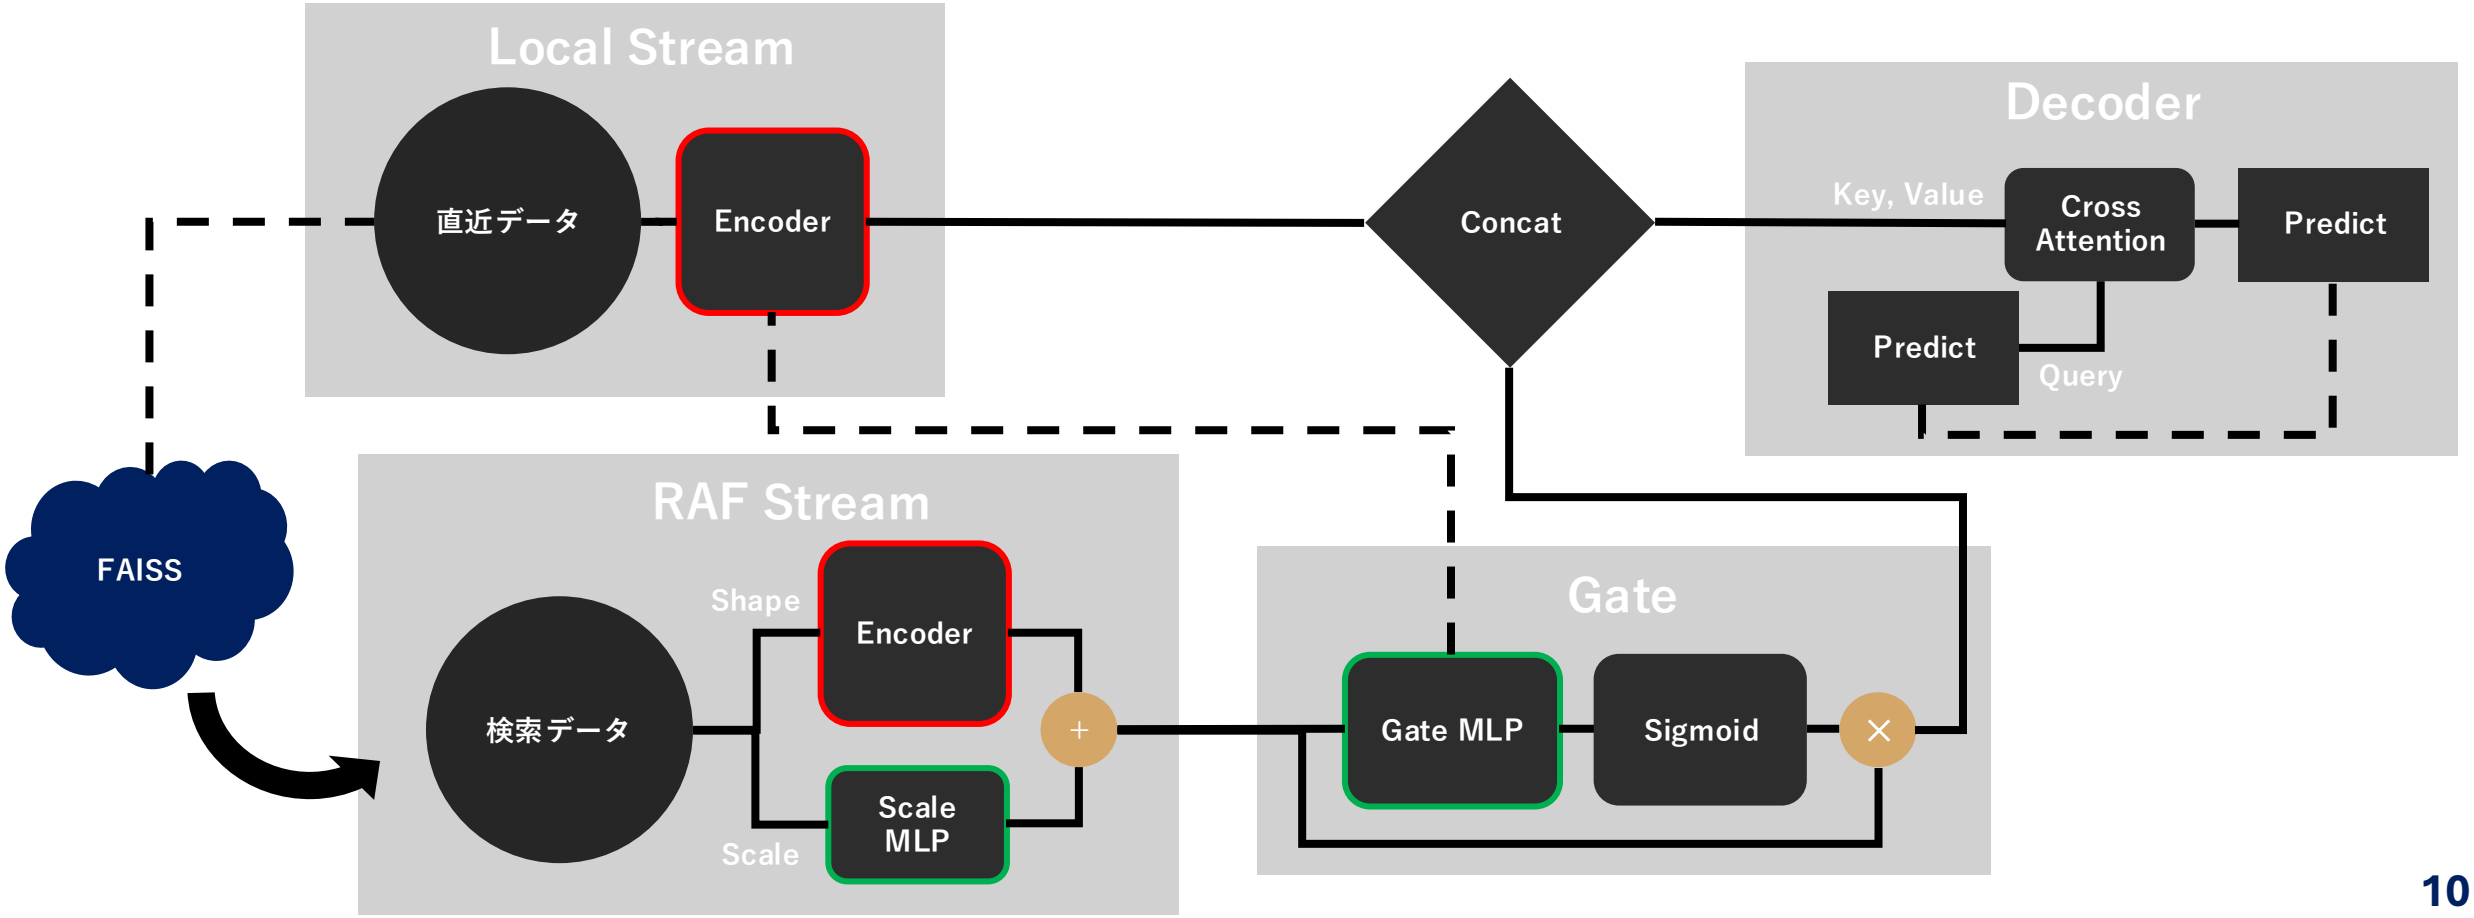

3. 提案手法　Gate付きRAFアーキテクチャ

Step2　Gateによる参照の選別

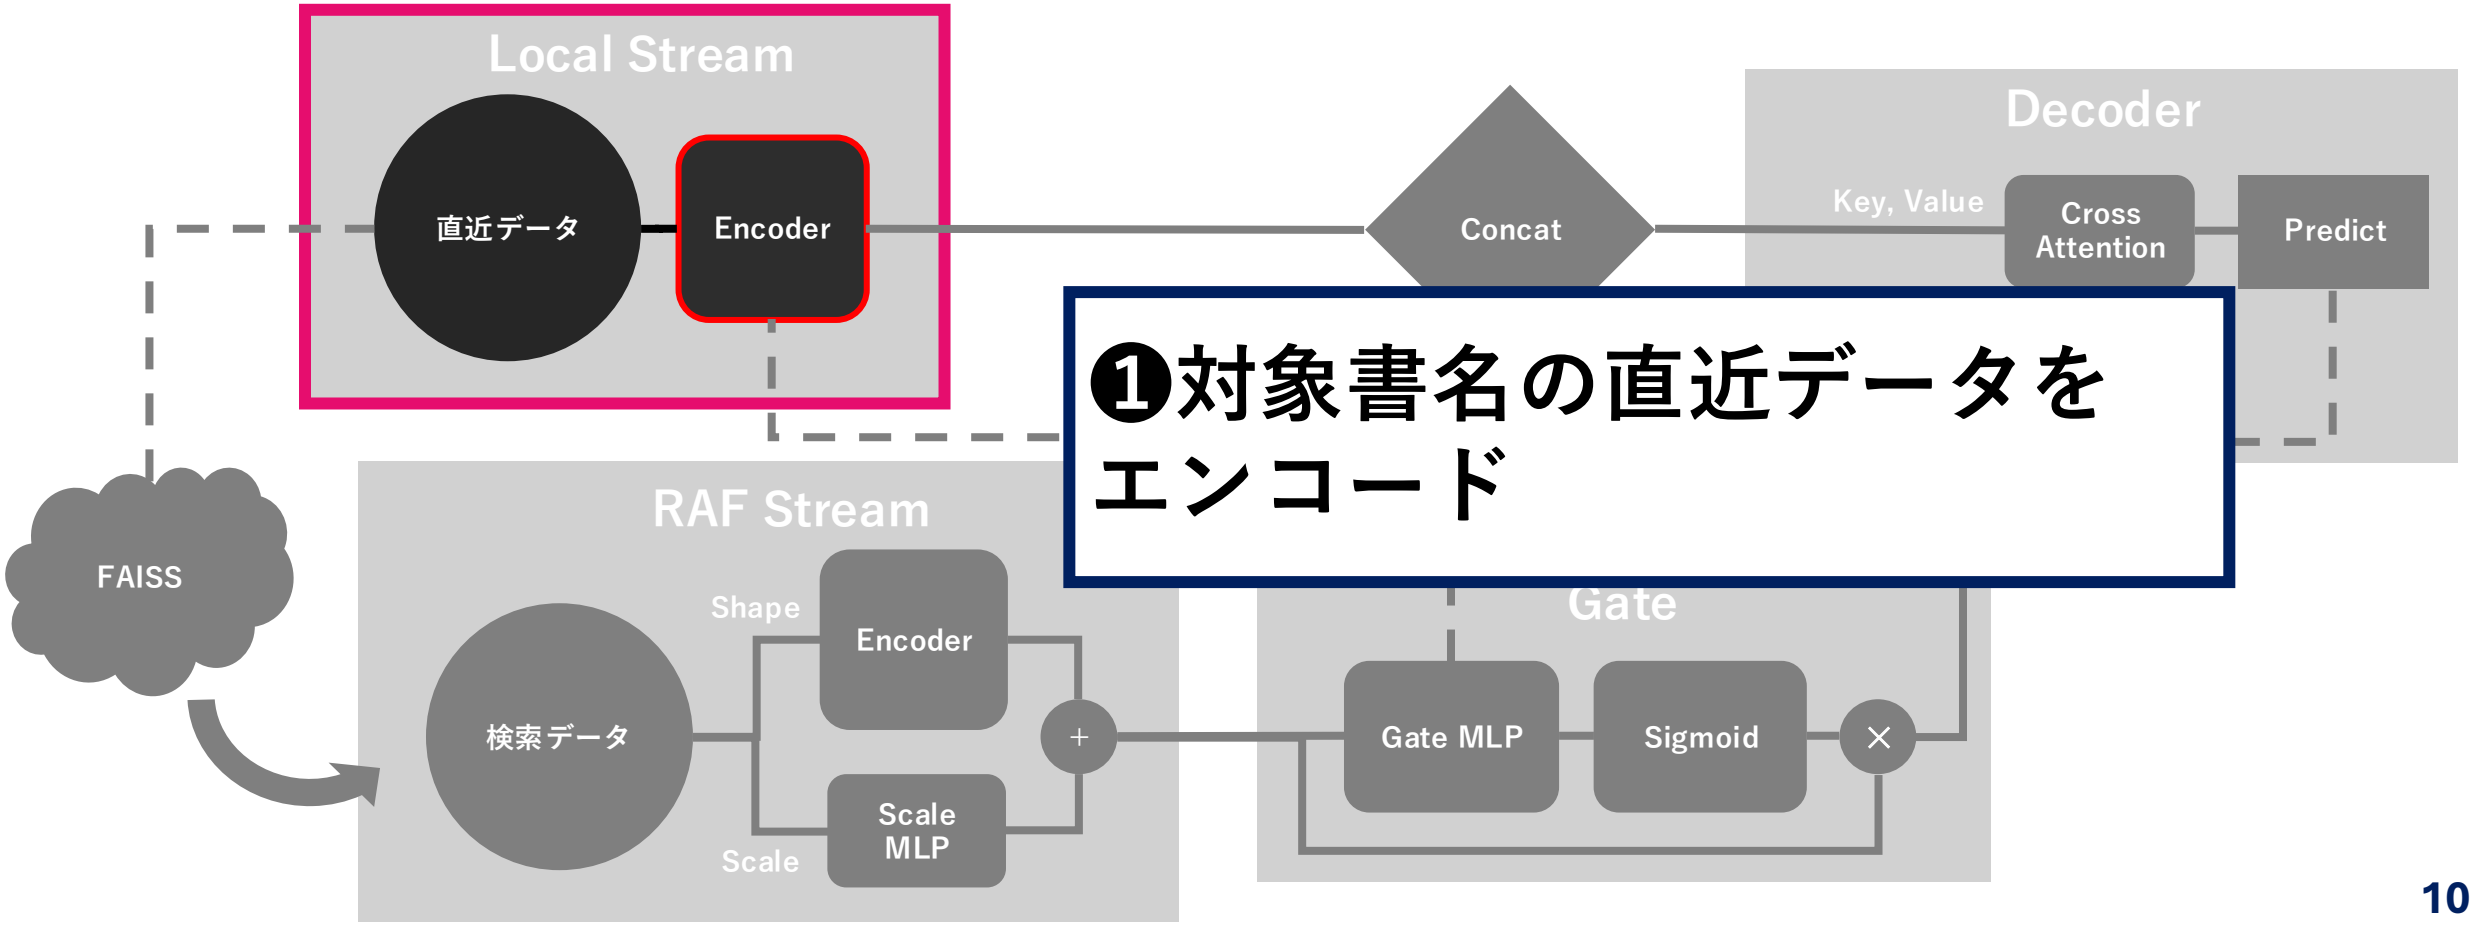

❶対象書名の直近データをエンコード

3. 提案手法　Gate付きRAFアーキテクチャ

Step2　Gateによる参照の選別

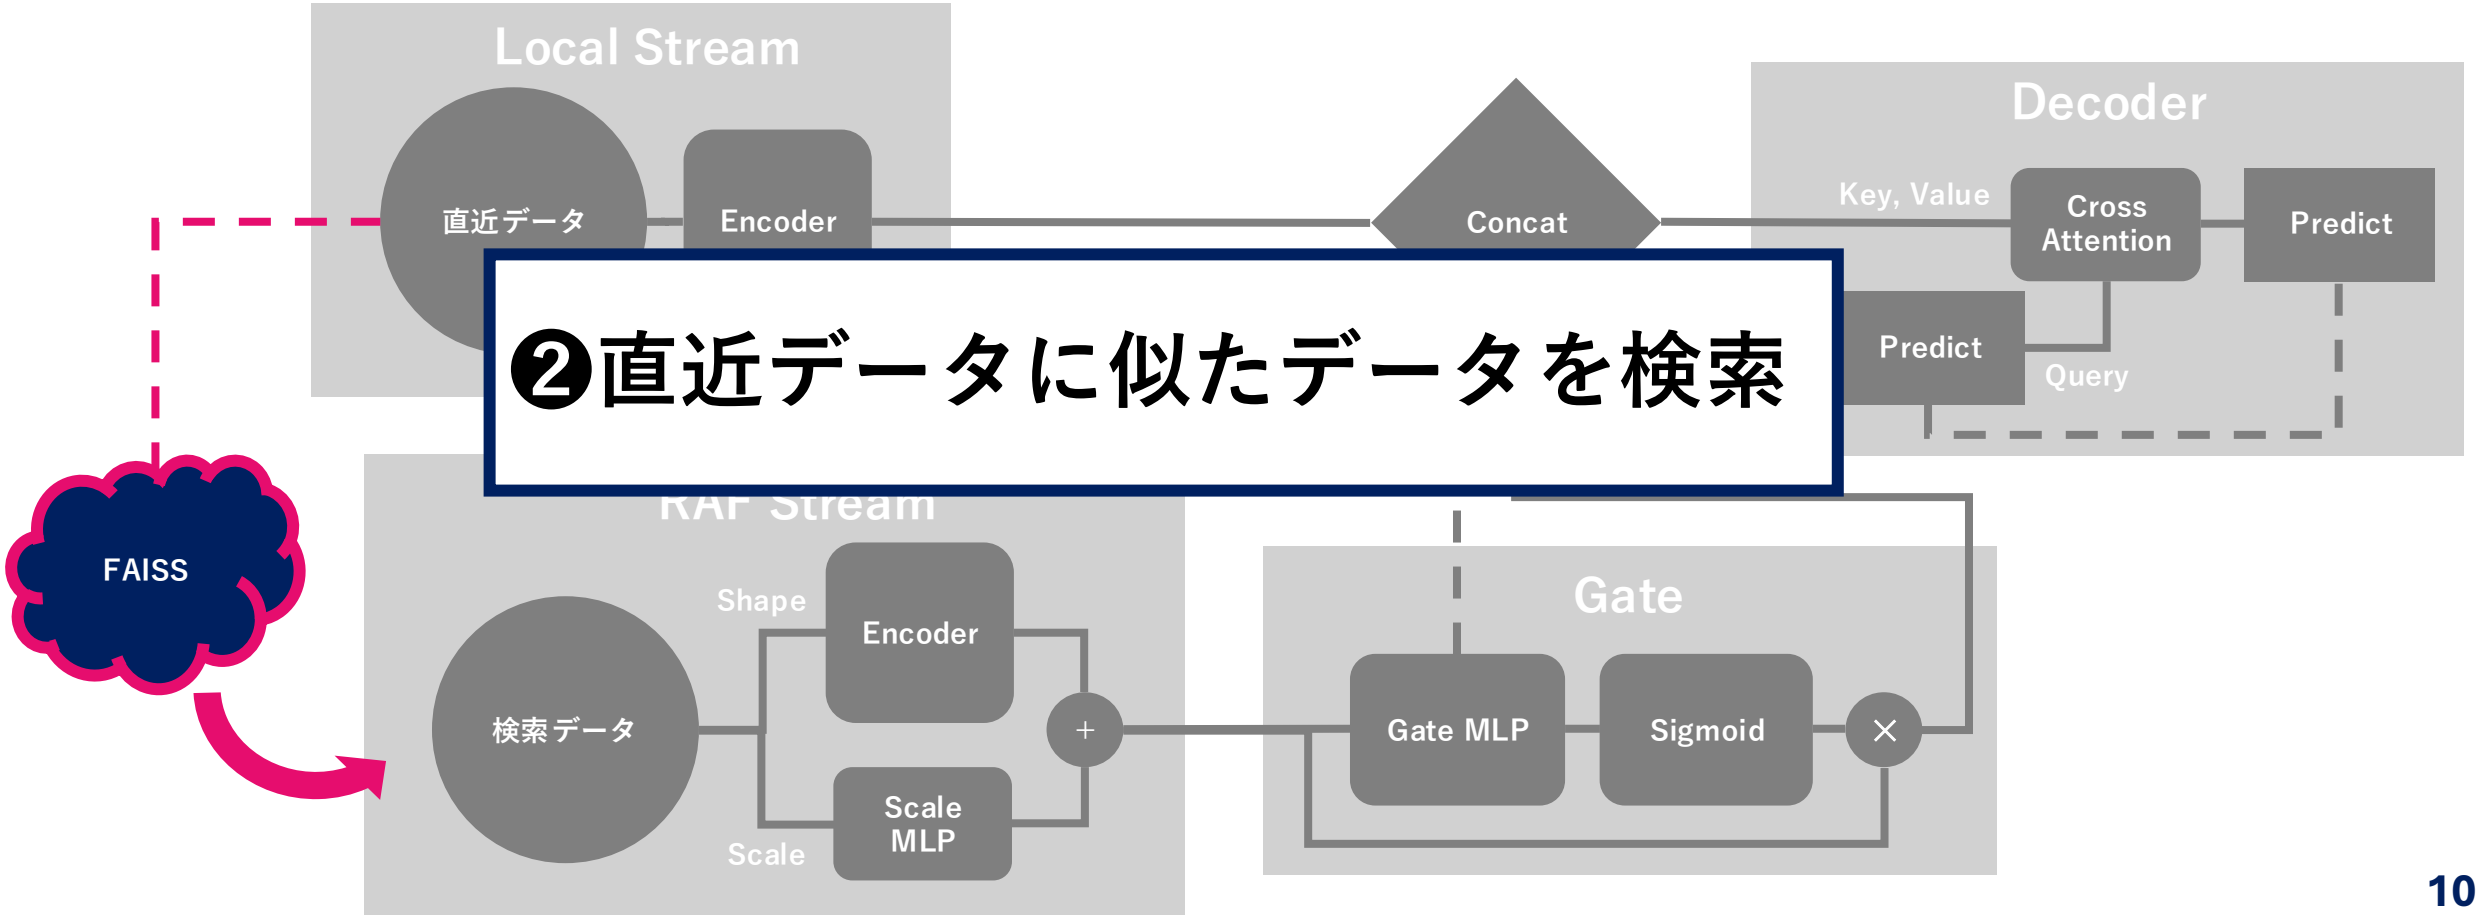

3. 提案手法　Gate付きRAFアーキテクチャ

Step2　Gateによる参照の選別

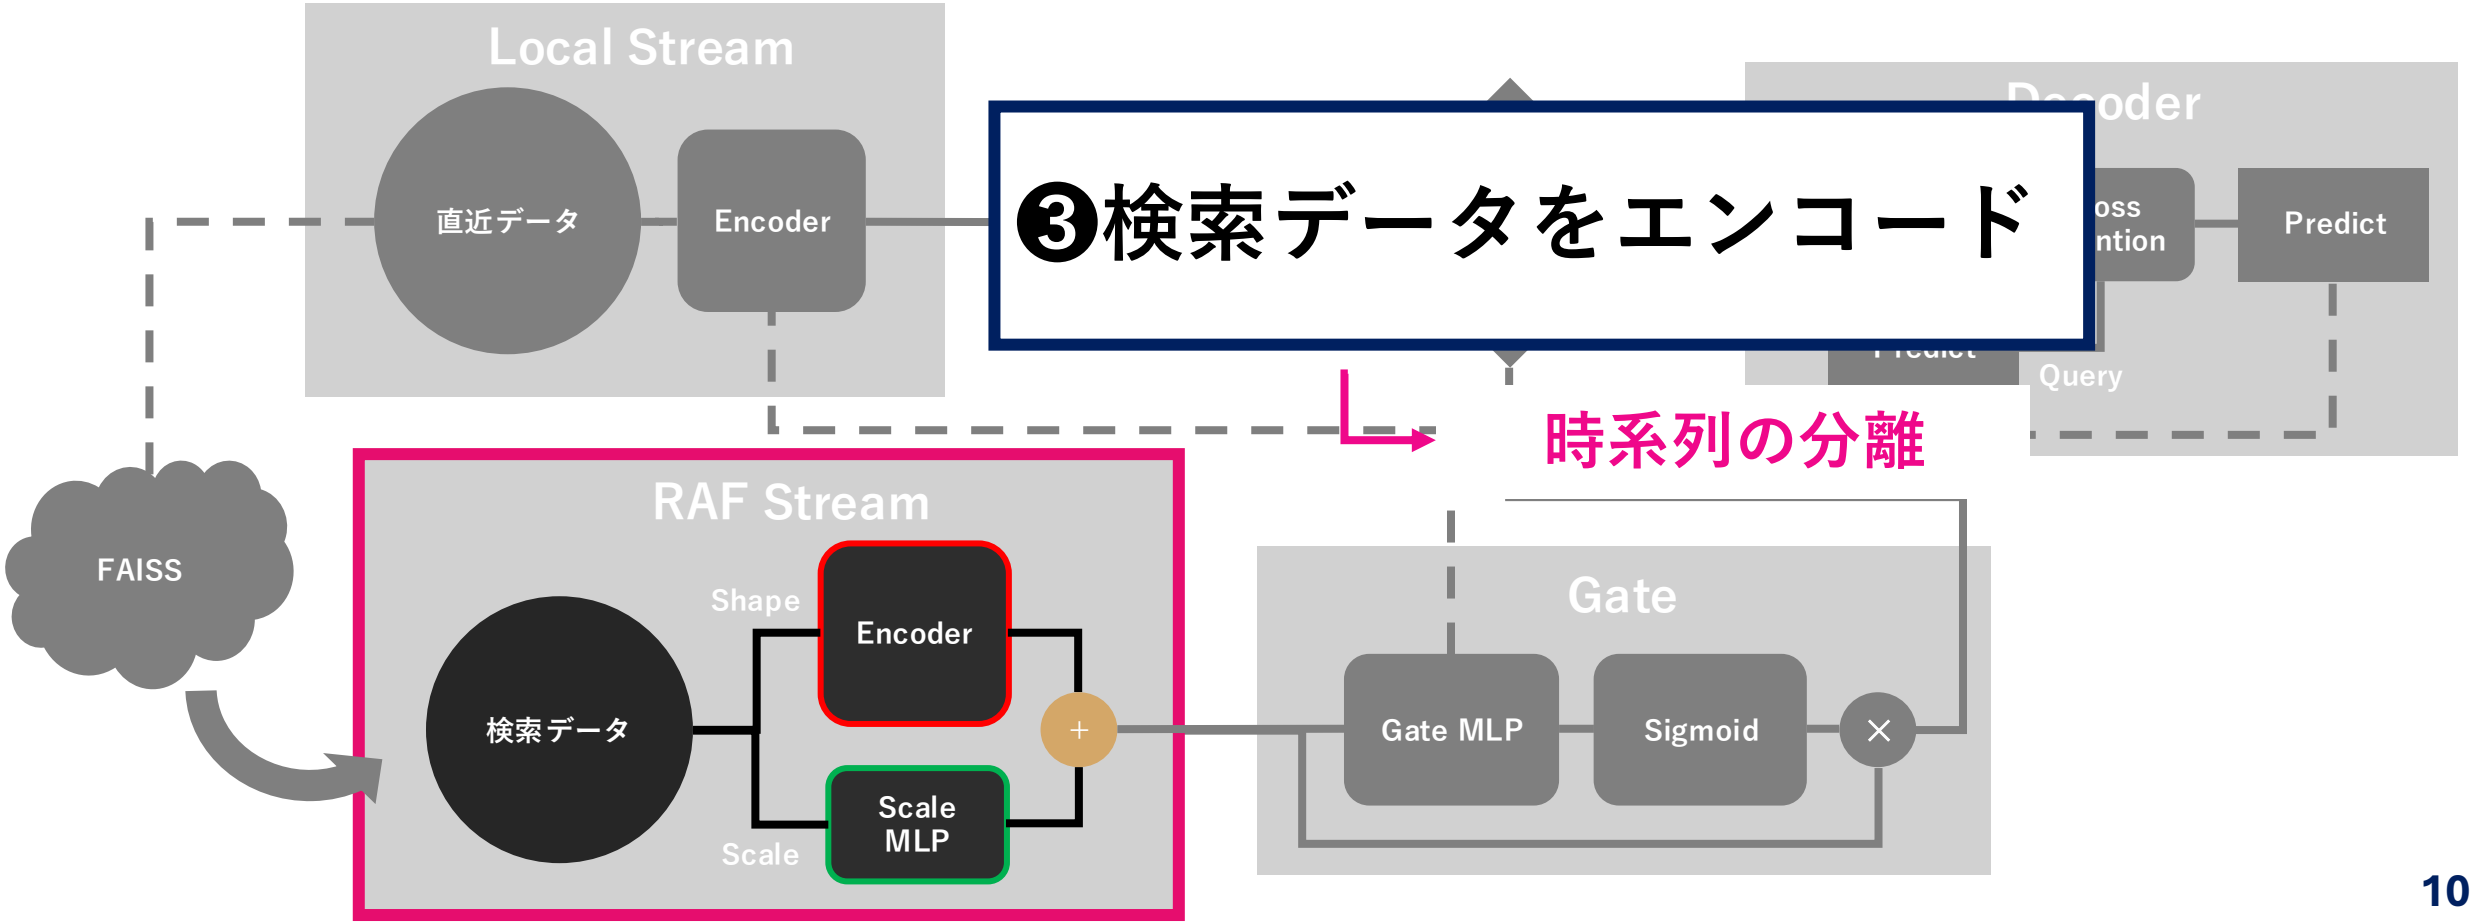

3. 提案手法　Gate付きRAFアーキテクチャ

Step2　Gateによる参照の選別

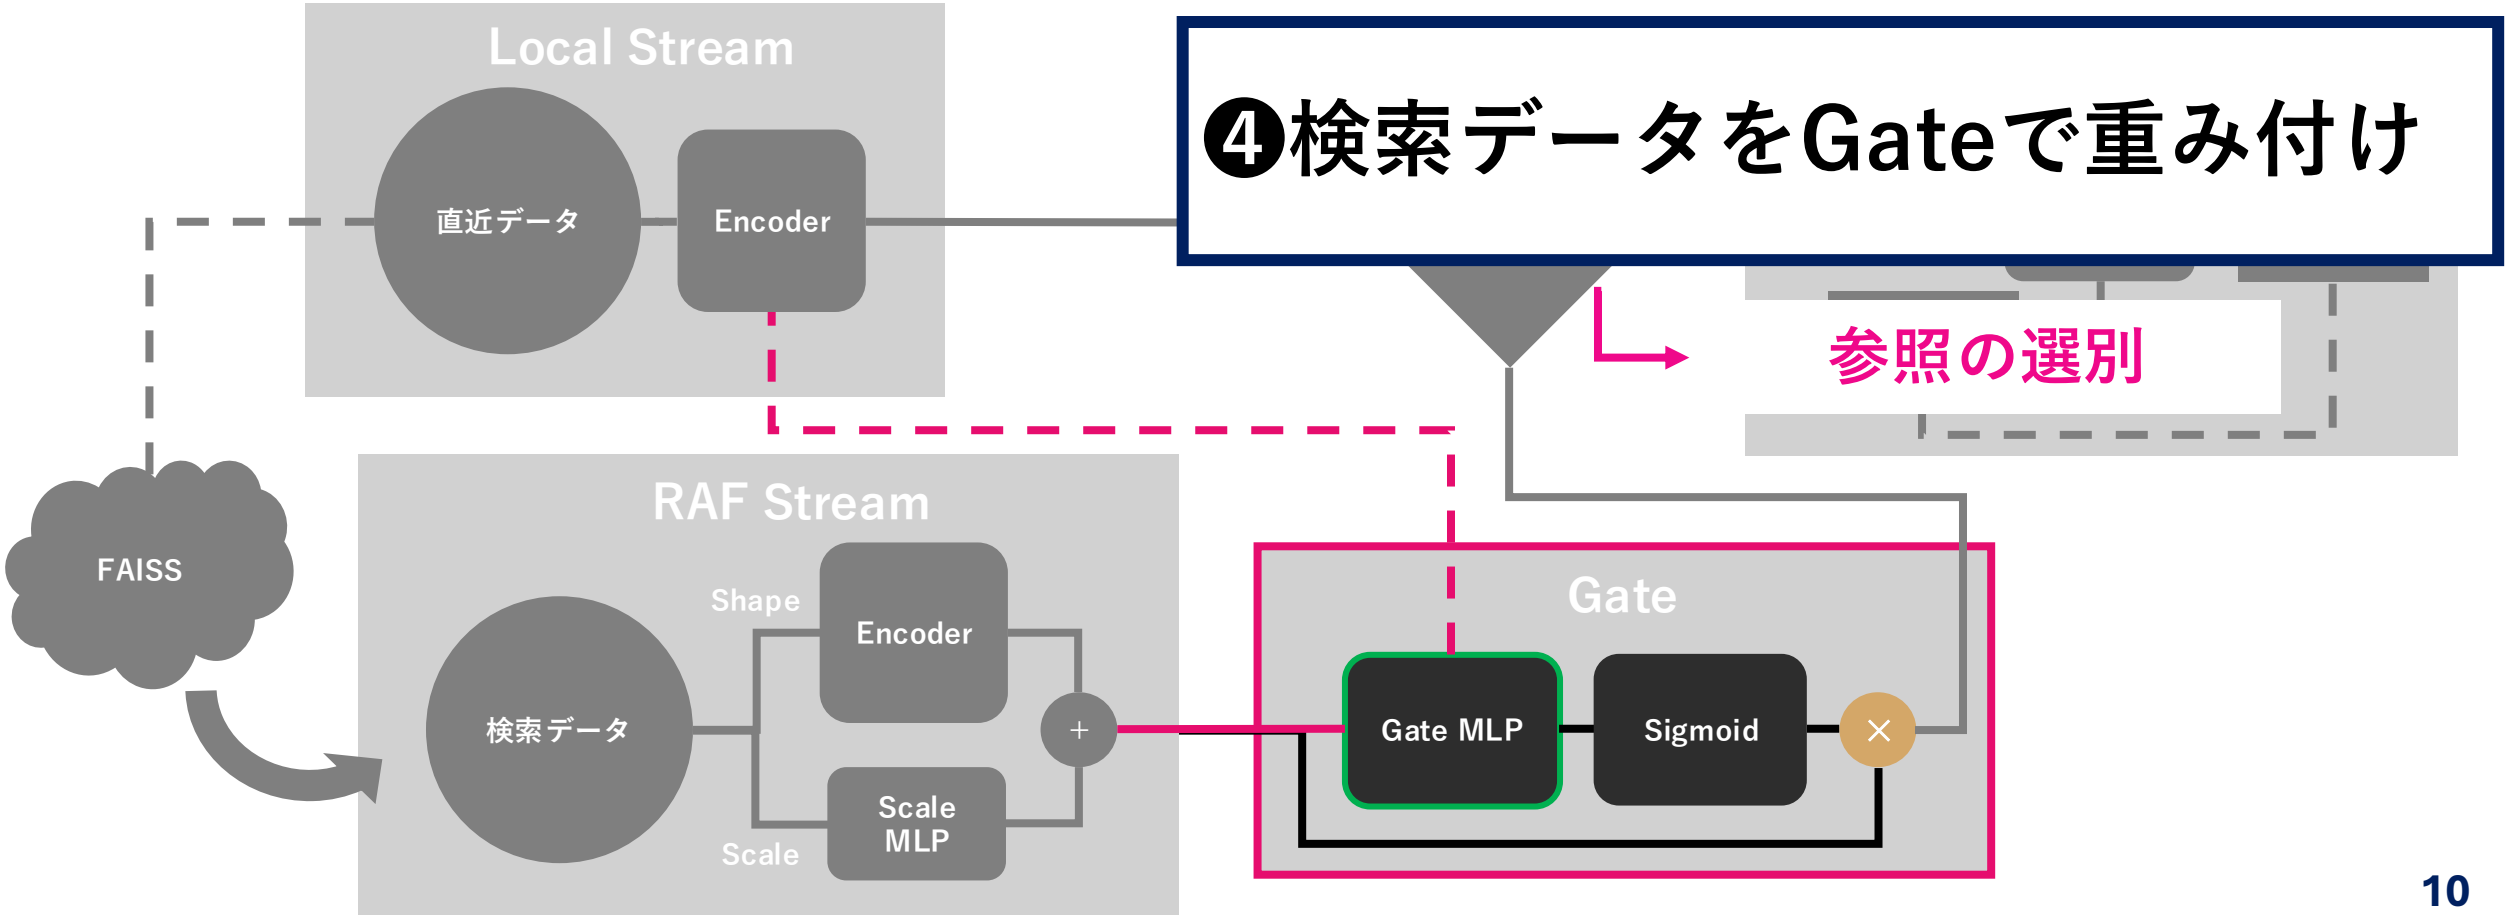

3. 提案手法　Gate付きRAFアーキテクチャ

Step2　Gateによる参照の選別

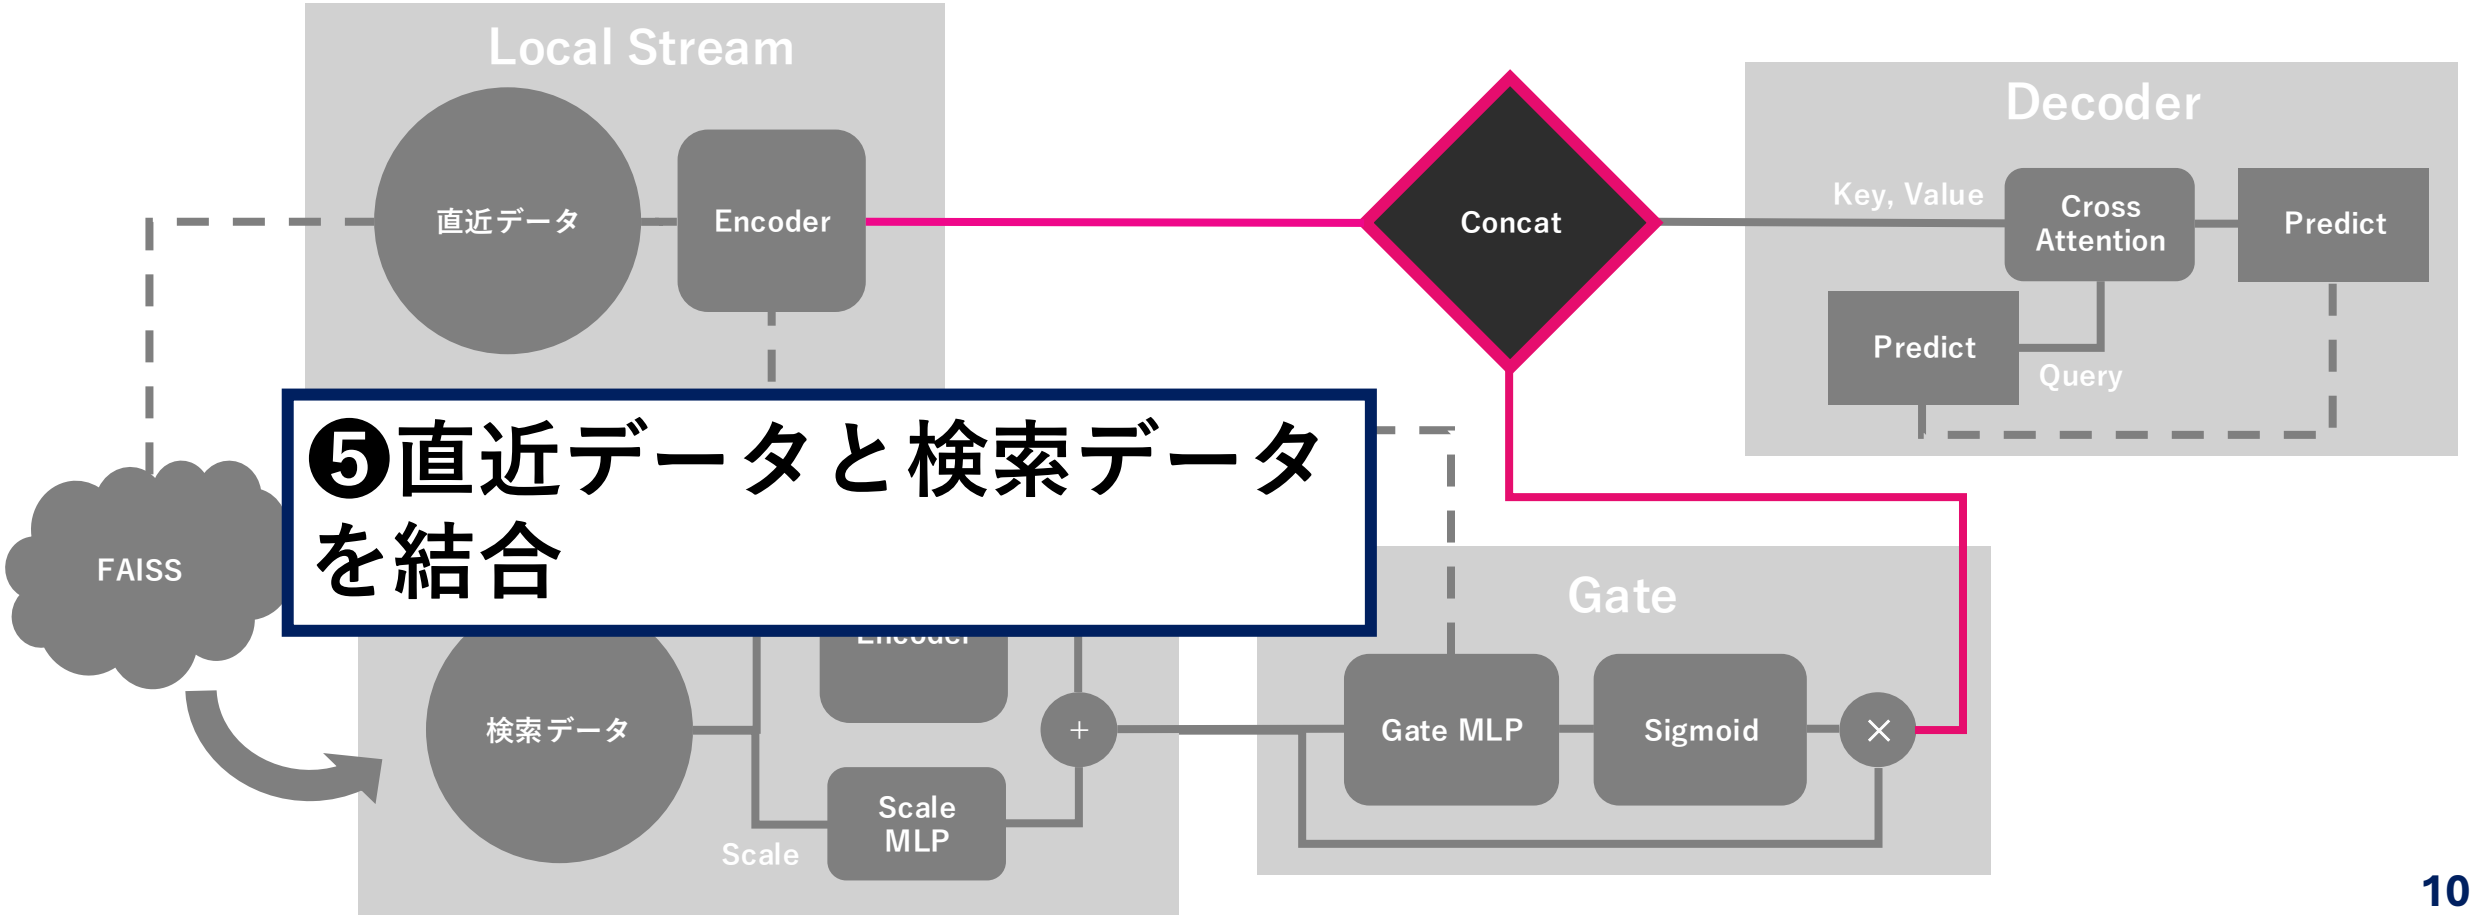

❺直近データと検索データを結合

3. 提案手法　Gate付きRAFアーキテクチャ

Step2　Gateによる参照の選別

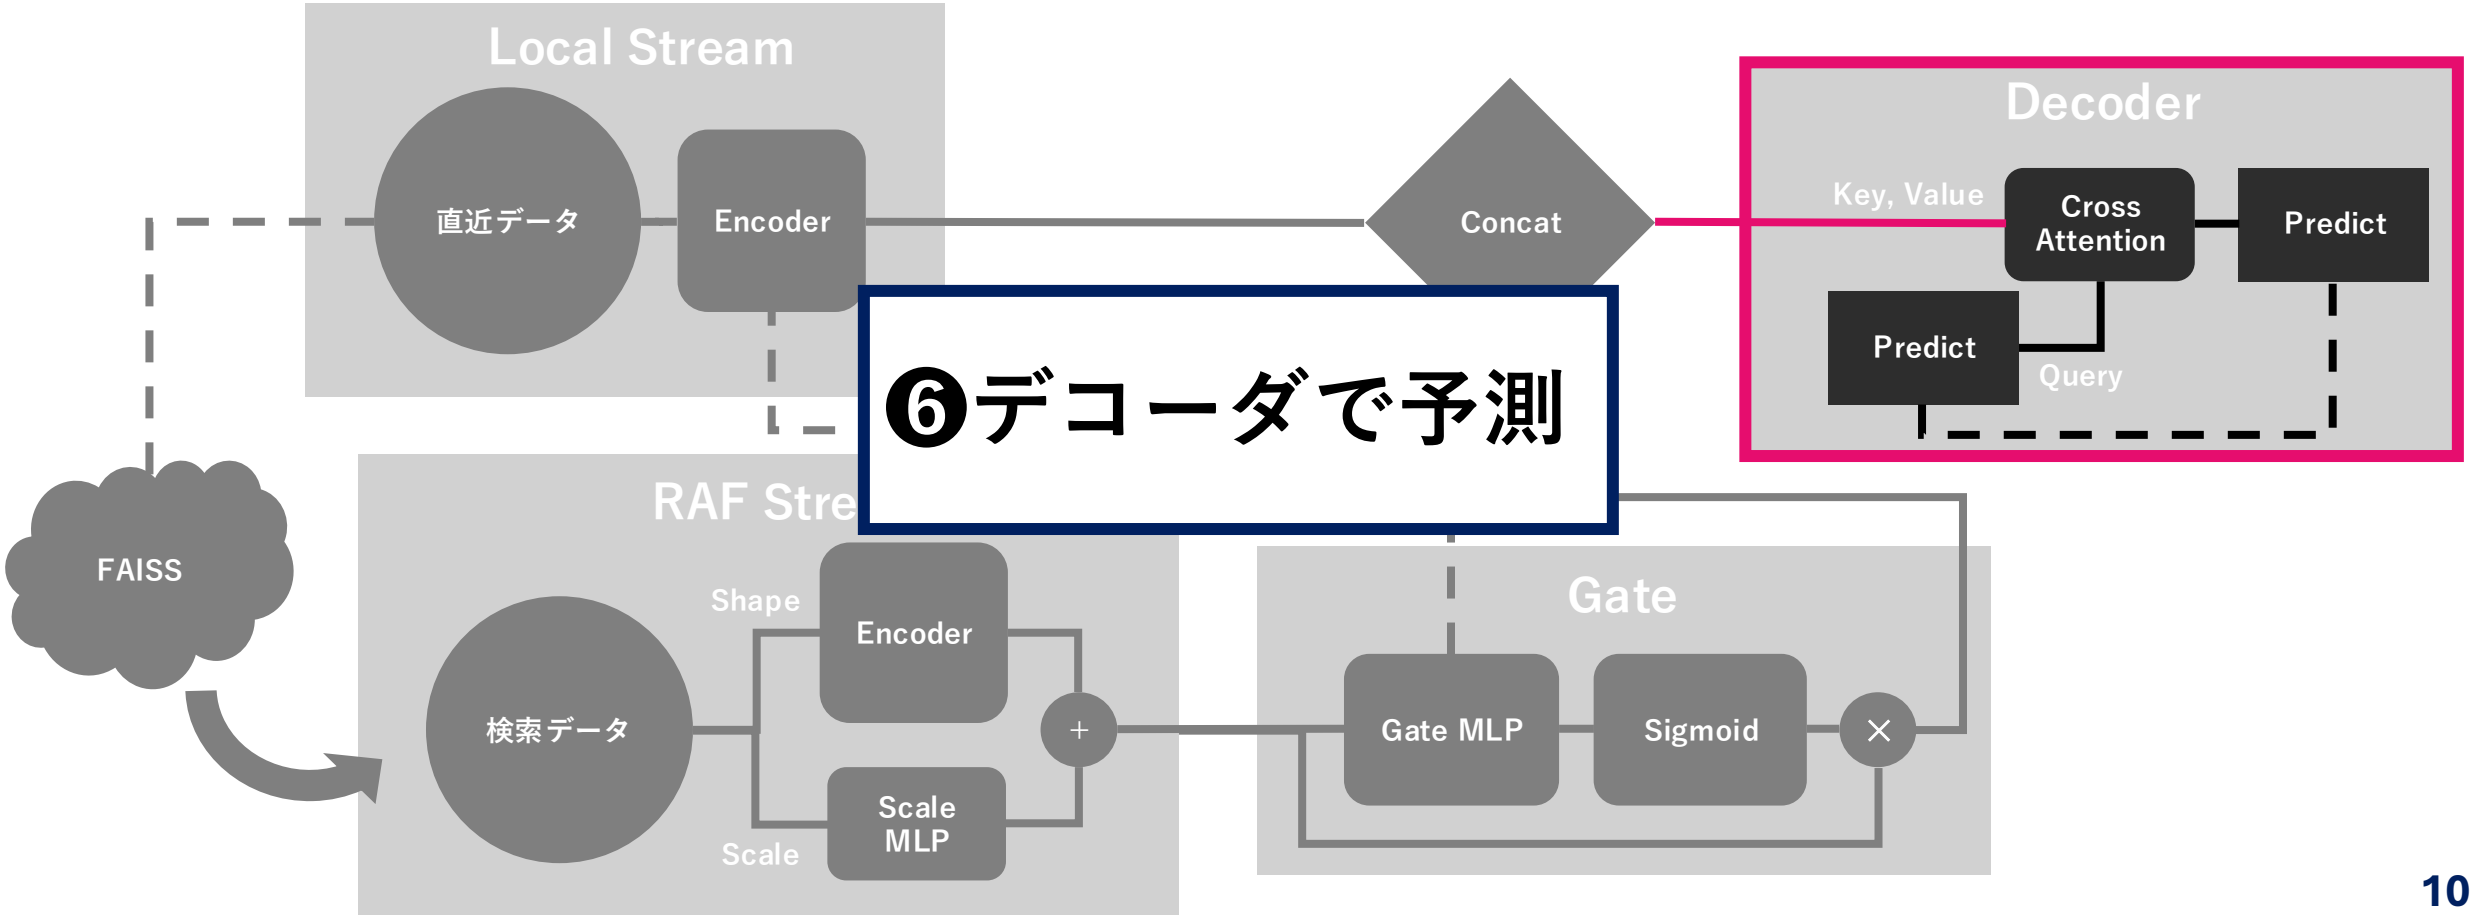

4. 実験概要

少ないデータ数で巨大なモデルを学習

事前学習済みモデル＋事後学習

事前学習済みモデル	Chronos_bolt-base
事後学習手法	DoRA

4. 実験概要

少ないデータ数で巨大なモデルを学習

事前学習済みモデル＋事後学習

事前学習済みモデル	Chronos_bolt-base
事後学習手法	DoRA

4. 実験概要

データ集計

＋

前処理

事後学習＋予測

モデル間の比較

実験1　モデルの選定

実験2・3に使うモデルを決定

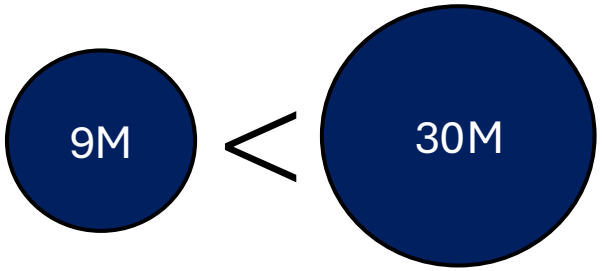

実験2　Gateの効果

Gateによる性能の向上を検証

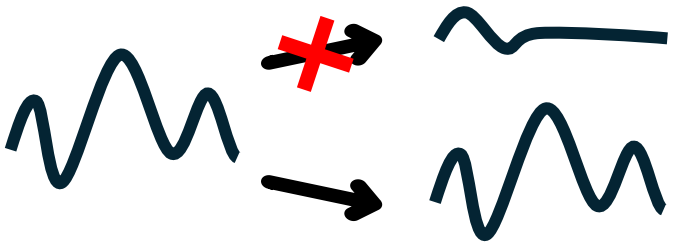

実験3　スパイク予測

スパイクに着目しモデルを比較

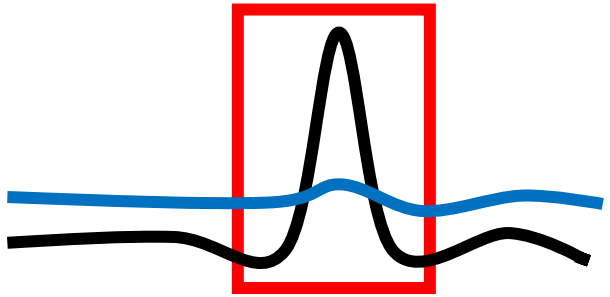

4. 実験概要

データ集計

＋

前処理

事後学習＋予測

モデル間の比較

実験1　モデルの選定

実験2・3に使うモデルを決定

9M ＜ 30M

実験2　Gateの効果

Gateによる性能の向上を検証

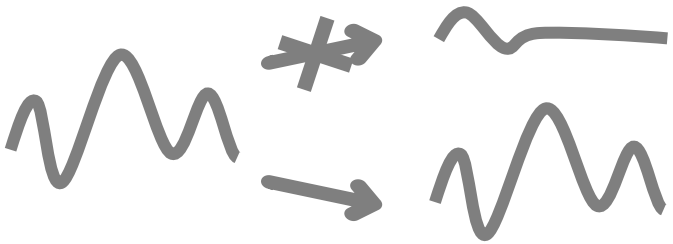

実験3　スパイク予測

スパイクに着目し精度を比較

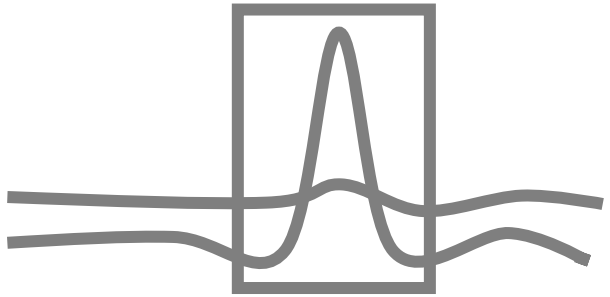

4. 実験概要

データ集計

＋

前処理

事後学習＋予測

モデル間の比較

実験1　モデルの選定

実験2・3に使うモデルを決定

9M < 30M

実験2　Gateの効果

Gateによる性能の向上を検証

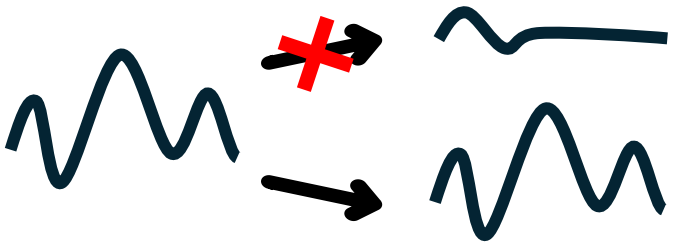

実験3　スパイク予測

スパイクに着目し精度を比較

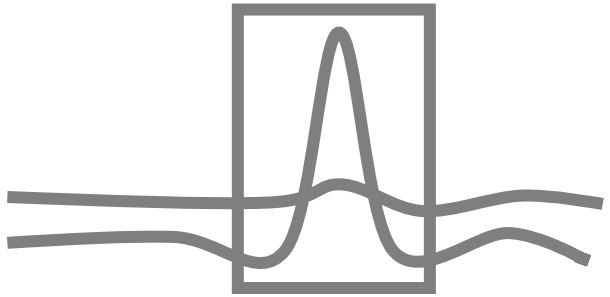

4. 実験概要

データ集計

＋

前処理

事後学習＋予測

モデル間の比較

実験1　モデルの選定

実験2・3に使うモデルを決定

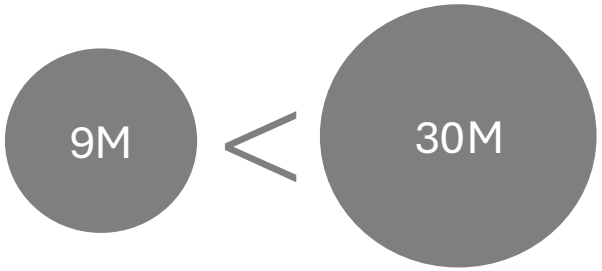

実験2　Gateの効果

Gateによる性能の向上を検証

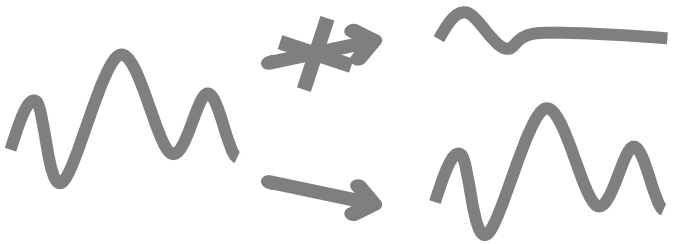

実験3　スパイク予測

スパイクに着目し精度を比較

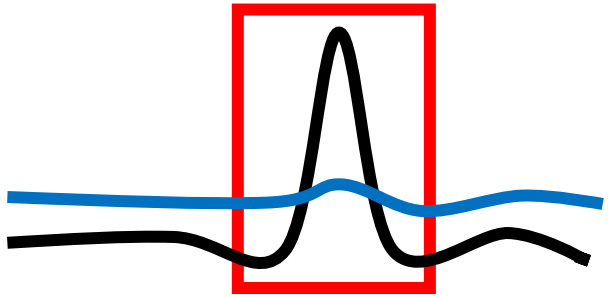

4. 実験概要　提供データ

書籍・雑誌販売データ

- 「日別」「書名別」「店舗別」の集計データ

識別情報	日付	2024/1/1～2024/12/31
	書名	書籍・雑誌のタイトル
	書店コード	書店に割り当てられた1~35の数字
購買情報	POS販売冊数	「日付」「書名」「書店コード」別の購買冊数
商品情報	ISBN	書籍・雑誌を識別する国際標準図書番号
	⋮	
	本体価格	購買時の税抜き価格

「日付」「書名」ごとの「POS販売冊数」を利用

4. 実験概要　提供データ

書籍・雑誌販売データ

・「日別」「書名別」「店舗別」の集計データ

識別情報	日付	2024/1/1～2024/12/31
	書名	書籍・雑誌のタイトル
	書店コード	書店に割り当てられた1~35の数字
購買情報	POS販売冊数	「日付」「書名」「書店コード」別の購買冊数
商品情報	ISBN	書籍・雑誌を識別する国際標準図書番号
	⋮	
	本体価格	購買時の税抜き価格

「日付」「書名」ごとの「POS販売冊数」を利用

4. 実験概要　提供データ

書籍・雑誌販売データ

特徴1　多品種少数生産

「日別」「書名」別の「POS販売冊数」分布

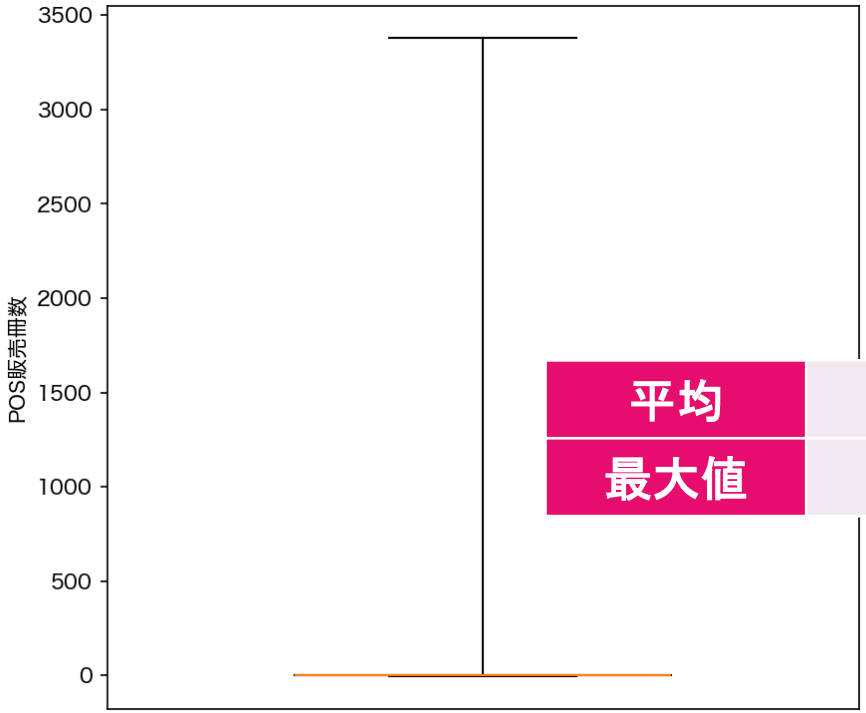

平均	0.0733
最大値	3,379

特徴2　突発な需要

「ぼっち・ざ・ろっく！1巻」POS販売冊数の推移

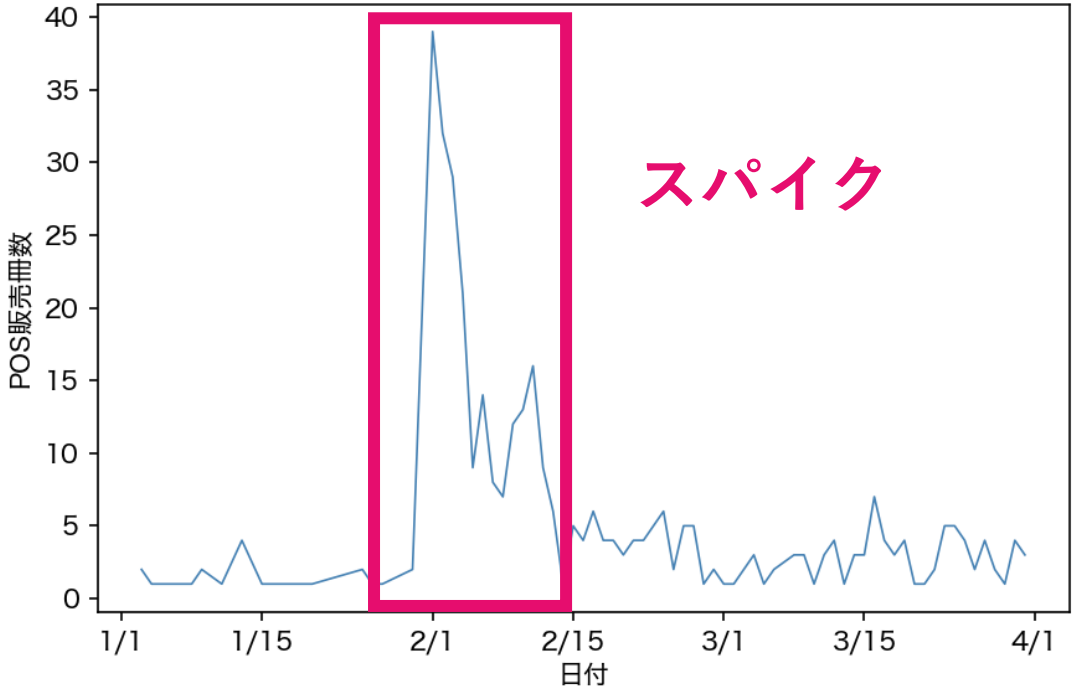

5. 実験1　モデルの選定

実験1-1　事後学習手法を比較

実験2・3に使うモデルを決定

モデル	比較事後学習手法
Chronos_bolt-tiny	LoRA
	DoRA
	IA^3
	Zero-shot

性能評価指標	
MAE	
RMSE	
QL0.1	← 平坦の予測精度
QL0.9	← スパイクの予測精度

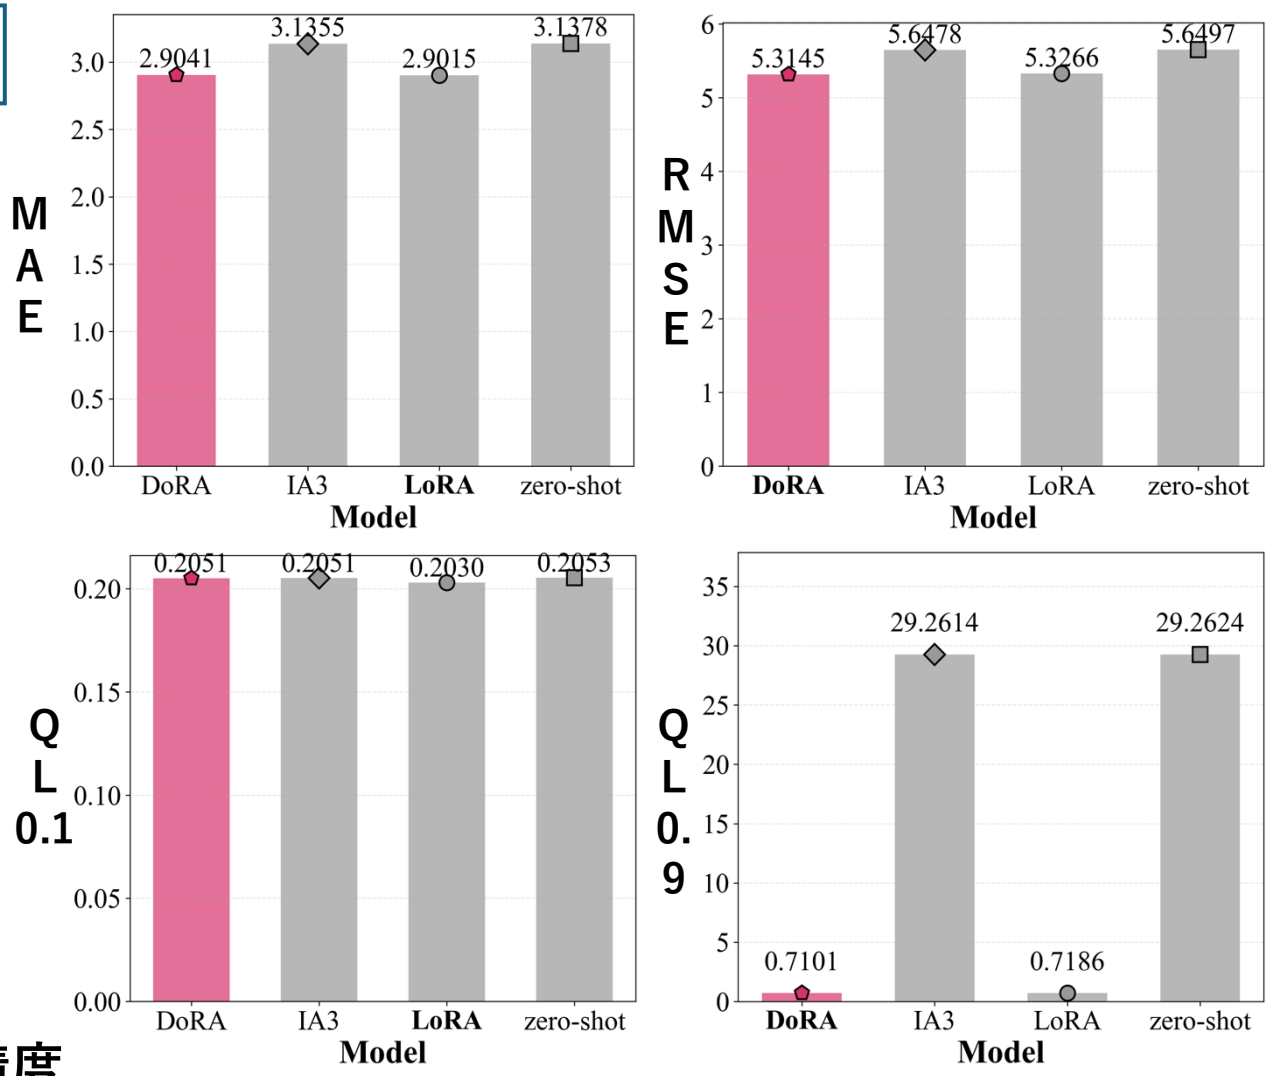

5. 実験1　モデルの選定

実験1-1　事後学習手法を比較

実験2・3に使うモデルを決定

LoRA・DoRAは2つの評価指標で
最高性能

QL0.9を考慮し

事後学習手法には**DoRA**を採用

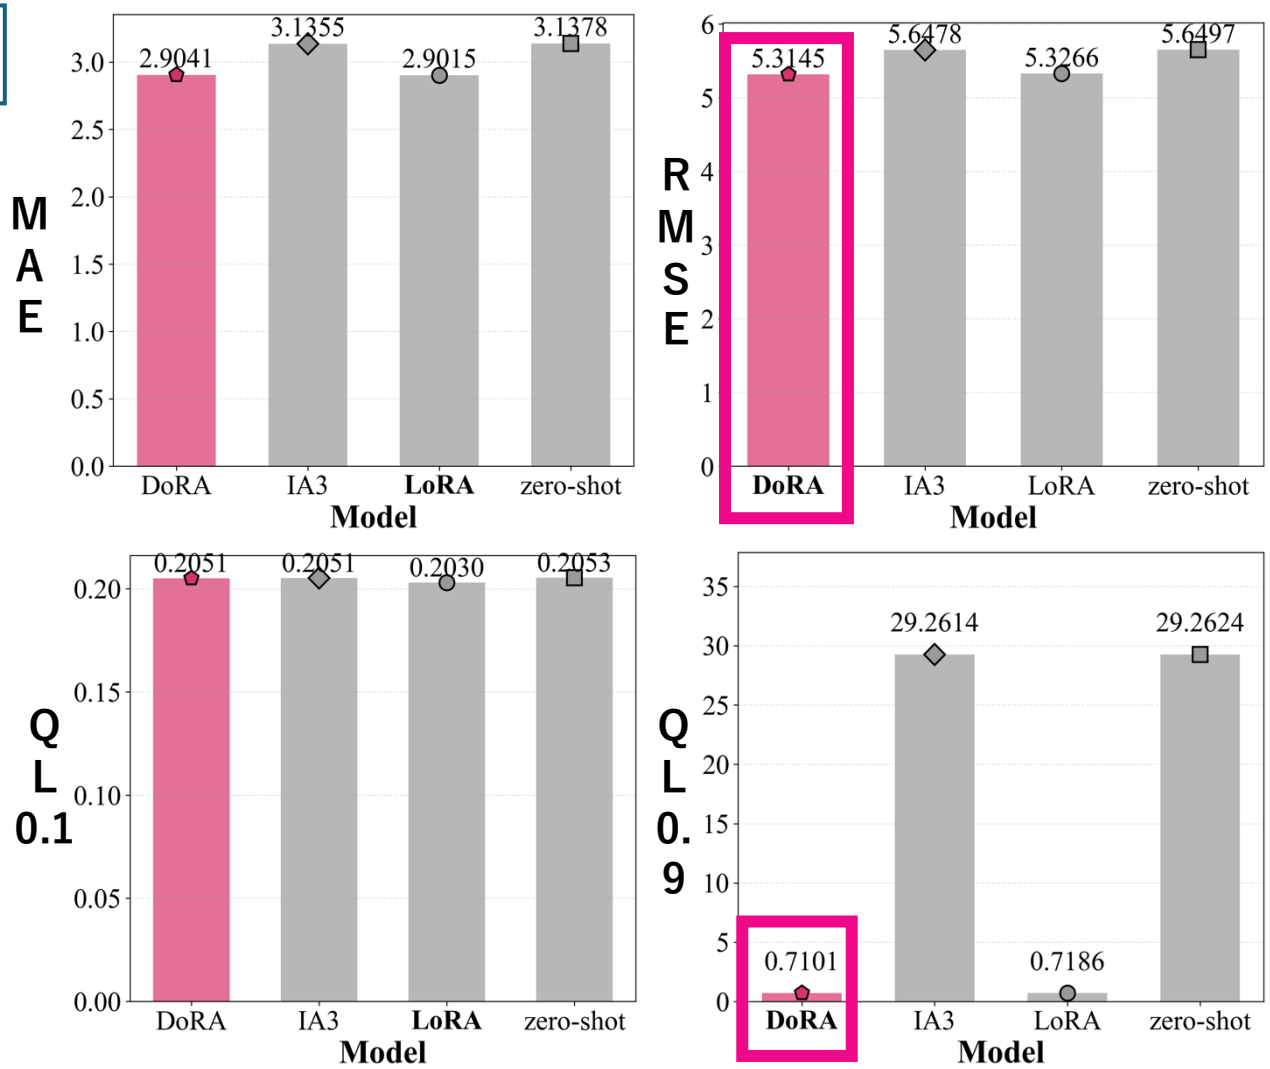

5. 実験1　モデルの選定

実験1-1　モデルサイズを比較

実験2・3に使うモデルを決定

比較モデル	モデルサイズ
Chronos_bolt-tiny	9M
Chronos_bolt-mini	21M
Chronos_bolt-small	48M
Chronos_bolt-base	205M

性能評価指標
MAE
RMSE
QL0.1
QL0.9

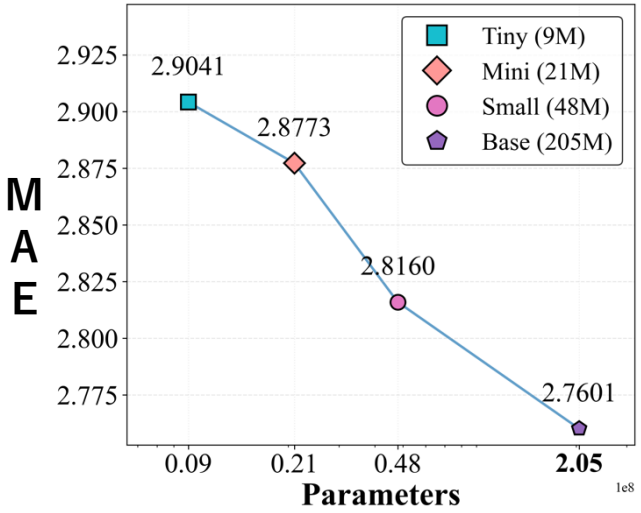

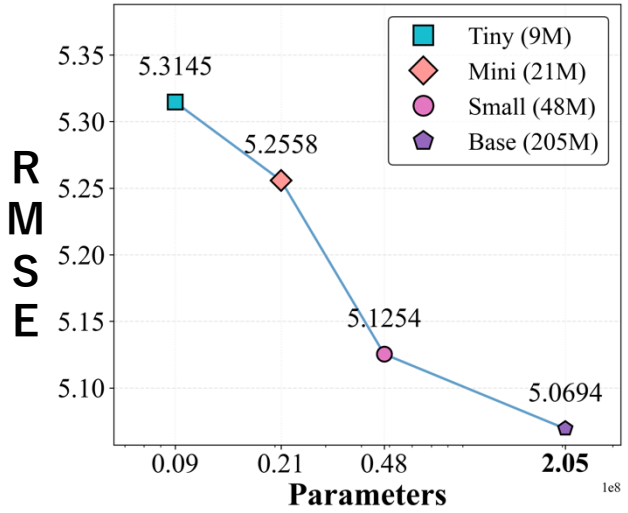

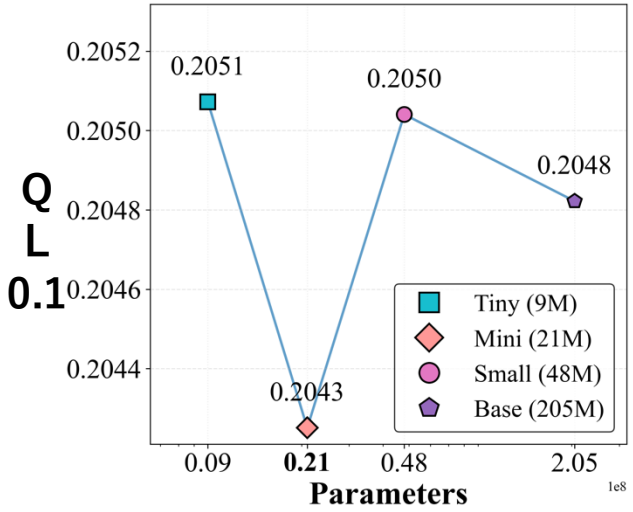

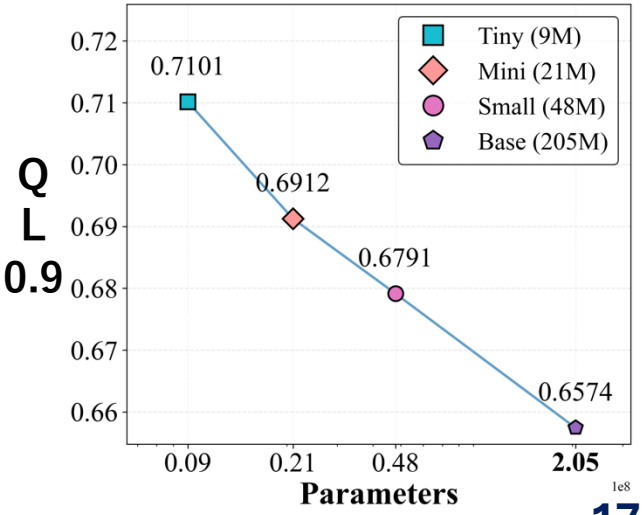

5. 実験1　モデルの選定

実験1-1　モデルサイズを比較

実験2・3に使うモデルを決定

モデルサイズと性能にべき乗則

モデルサイズが最大の
Chronos_bolt-baseを採用

以下Chronos_boltはChronos_bolt-baseとする

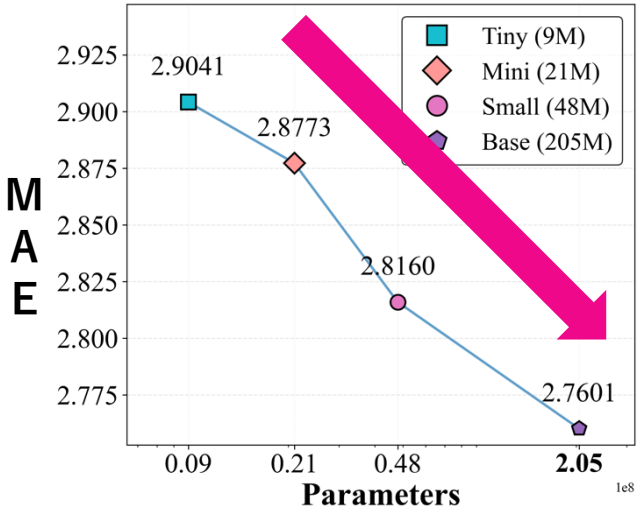

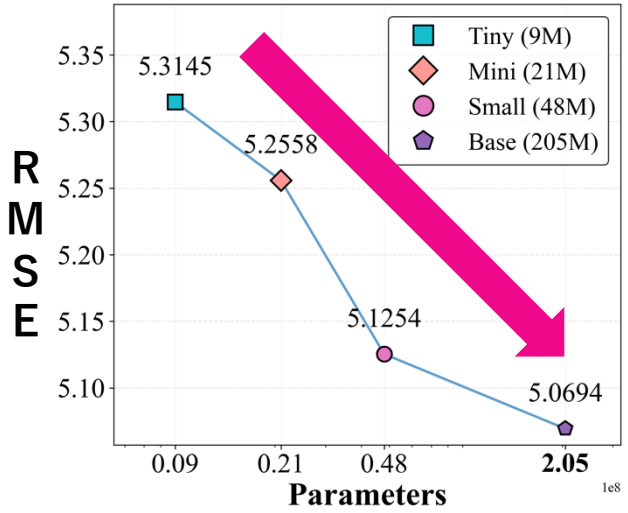

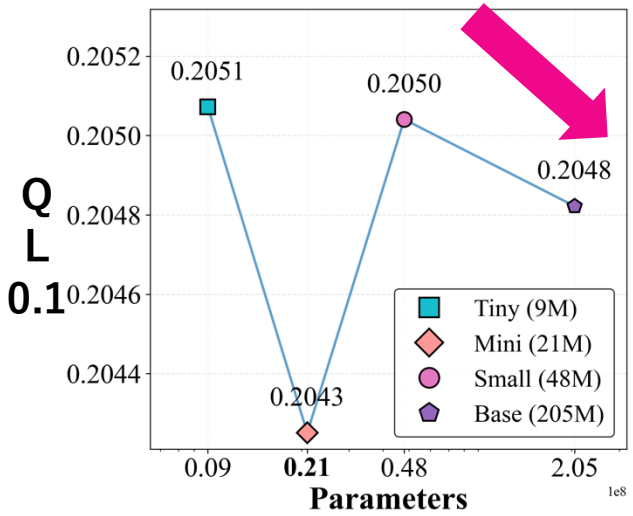

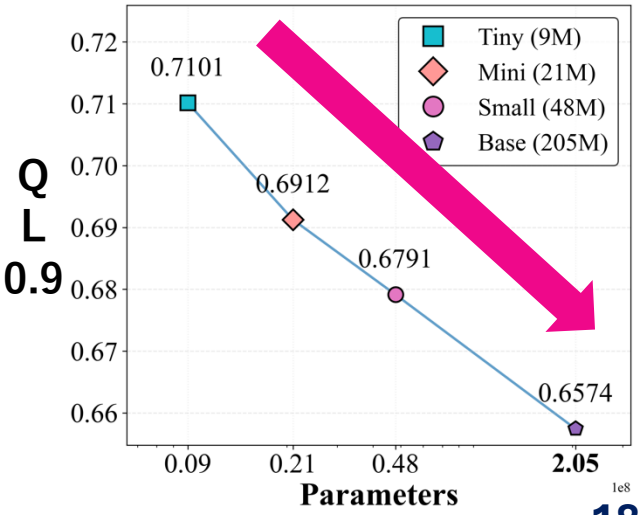

5. 実験2　Gateの効果

実験2　Gateの効果

Gateによる性能の向上を検証

モデル	比較RAF	
Chronos_bolt	Gate-RAF	
	Proto-RAF	← Gateなし
	no-RAF	← RAFなし

性能評価指標
MAE
RMSE
QL0.1
QL0.9

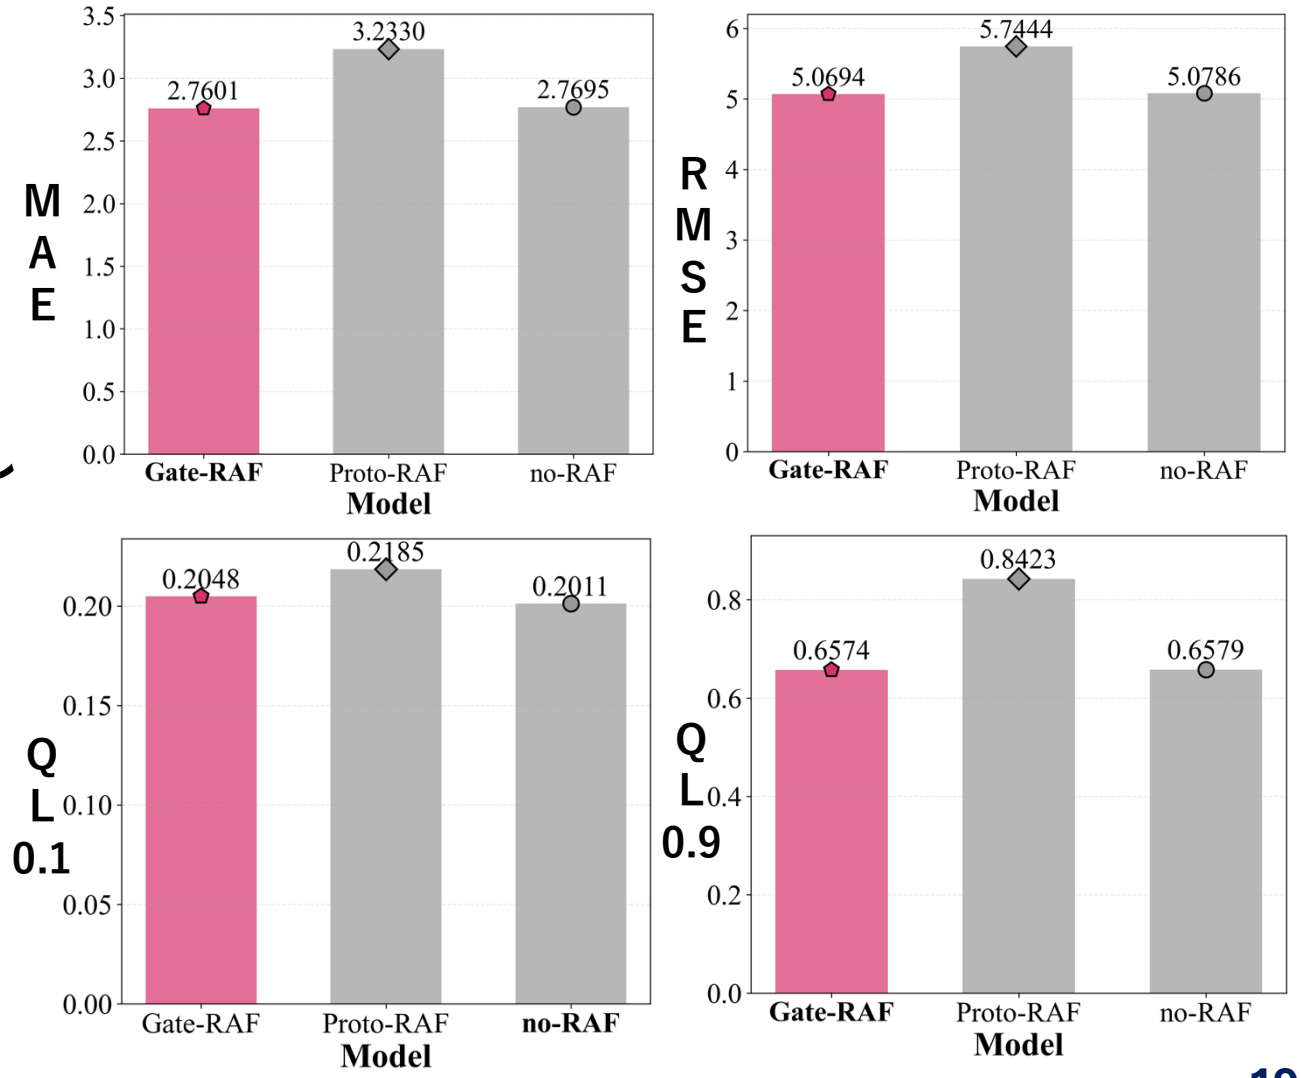

Proto-RAF：Prototype-RAF(GateがないRAF)

5. 実験2　Gateの効果

実験2　Gateの効果

Gateによる性能の向上を検証

Gate付きRAFが
3つの評価指標で最高性能

Proto-RAFはno-RAFより性能悪化
Gateなし　RAFなし

↑

Multi-streamとGateによって攻略
→提案手法の優位性

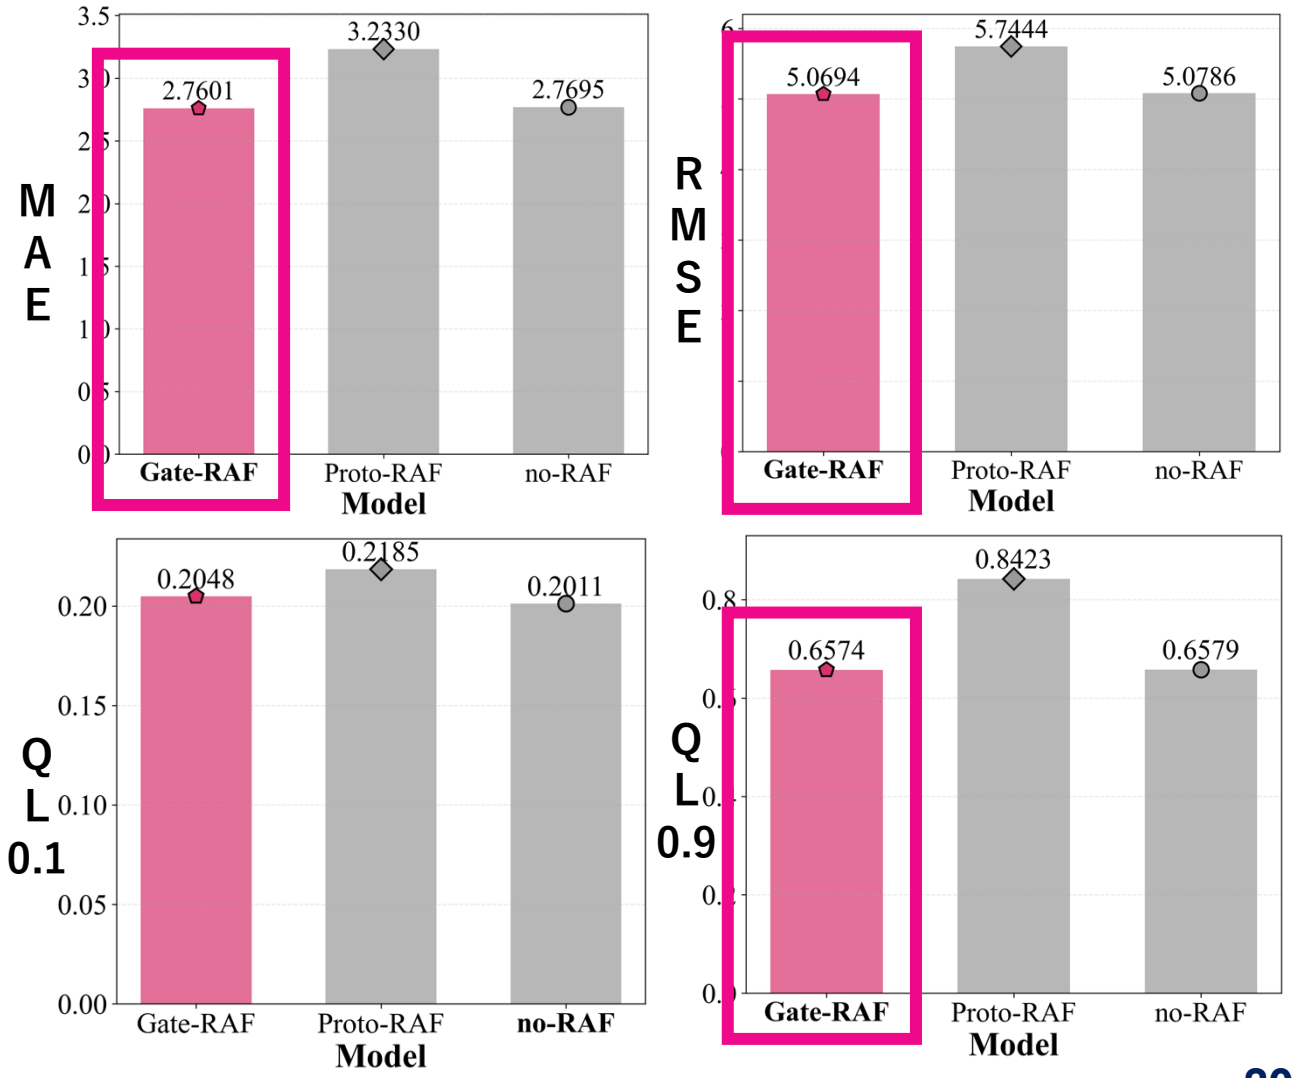

5. 実験2　Gateの効果

実験2	Gateの効果

Gateによる性能の向上を検証

Gate付きRAFが
3つの評価指標で最高性能

Proto-RAFはno-RAFより性能悪化
Gateなし　　そもそもRAFなし

↑

Multi-streamとGateによって攻略
→提案手法の優位性

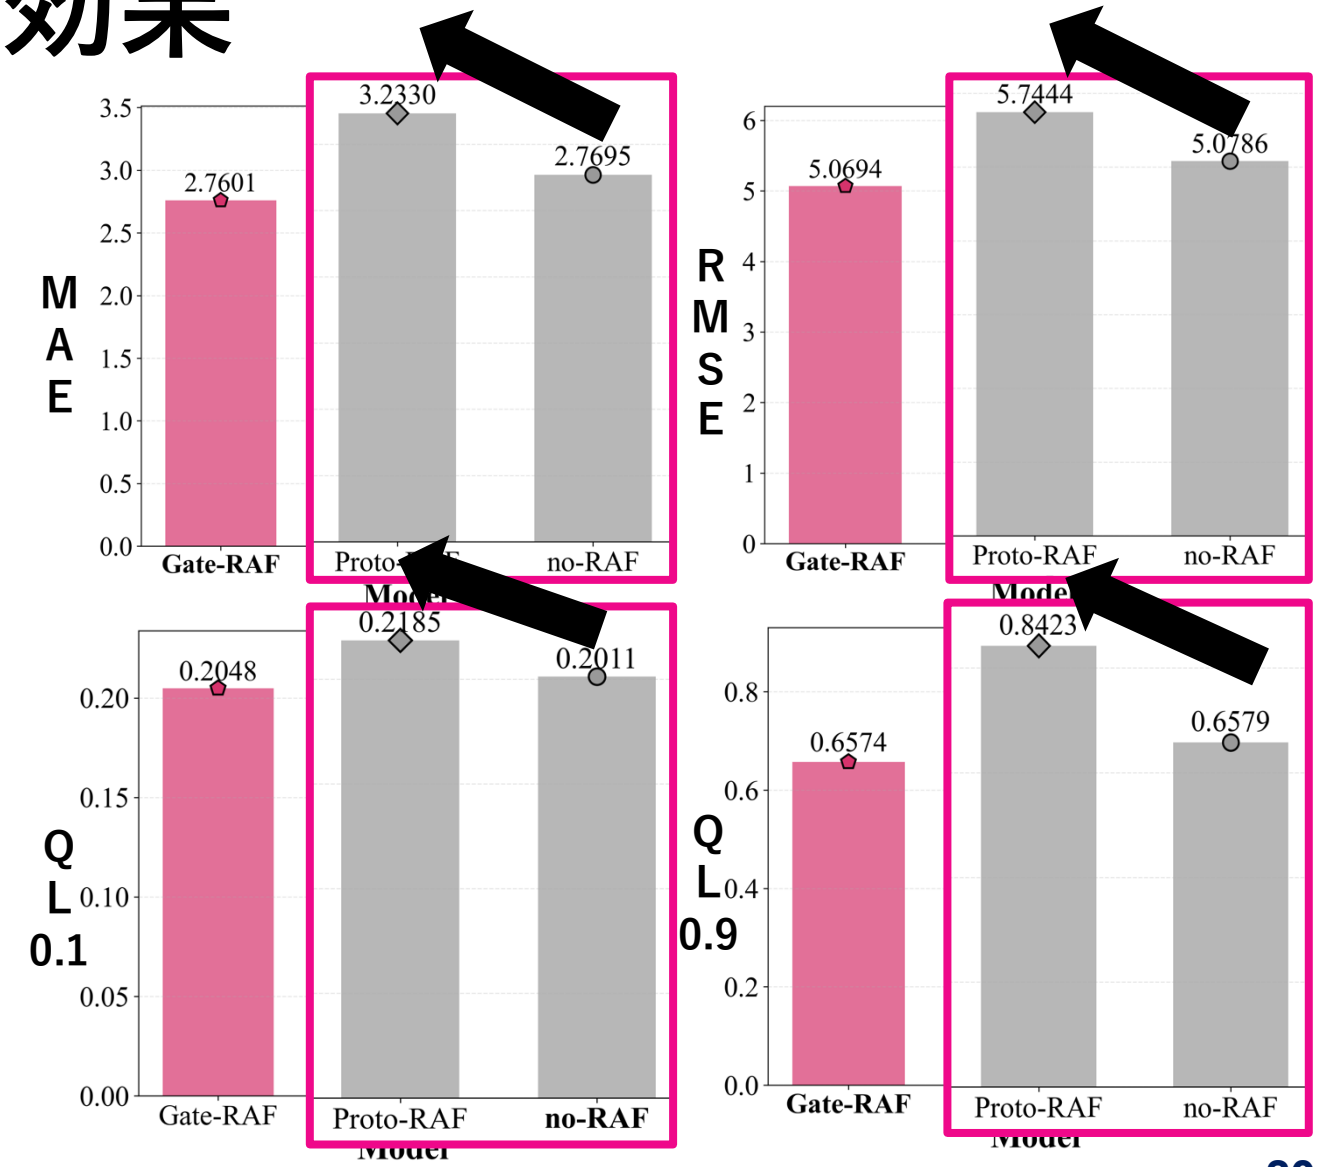

5. 実験3　スパイク予測

実験3　スパイク予測の比較

スパイクに着目し精度を比較

比較モデル	
Chronos_bolt+Gate-RAF	← 提案手法
SARIMA	← 従来手法

「月刊ＴＶガイド関東版」の予測結果

Gate-RAF

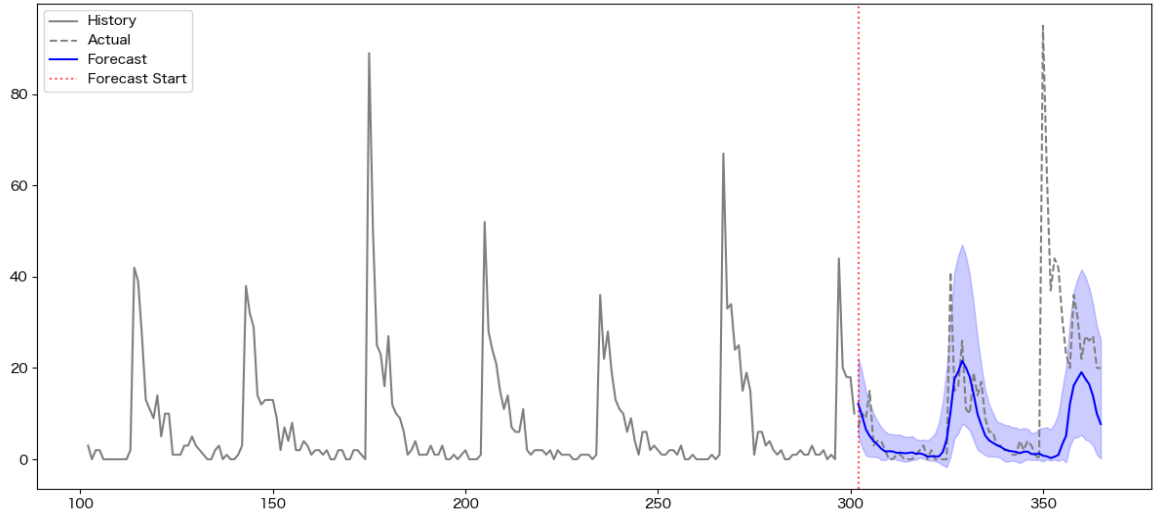

SARIMA

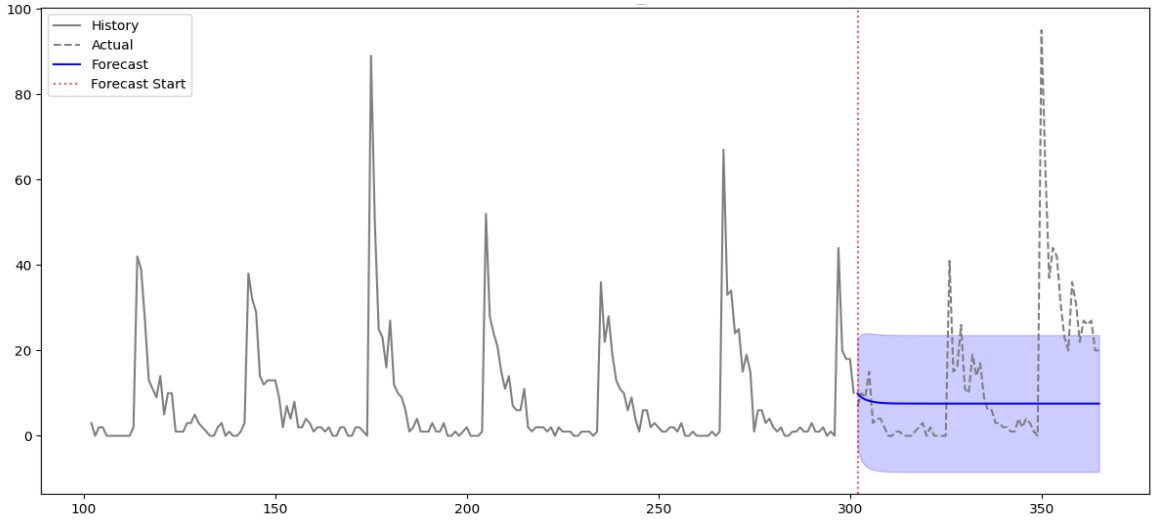

5. 実験3　スパイク予測

実験3　スパイク予測の比較

スパイクに着目し精度を比較

提案手法
(Gate-RAF)

❶平らな予測を回避し，スパイクを予測

＋

❷予測区間が狭い

←予測の確信度が高い

「月刊ＴＶガイド関東版」の予測結果

Gate-RAF

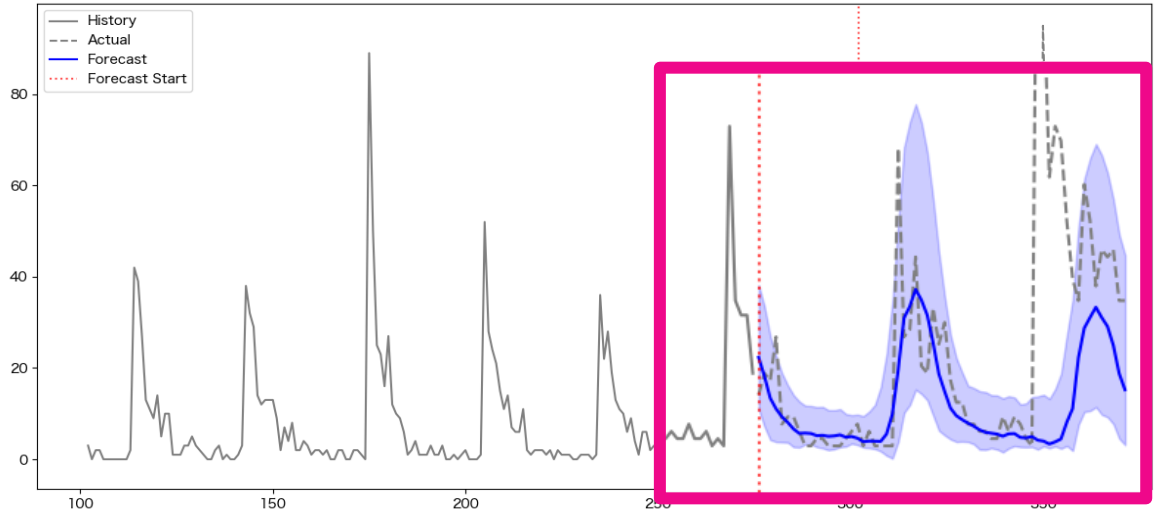

SARIMA

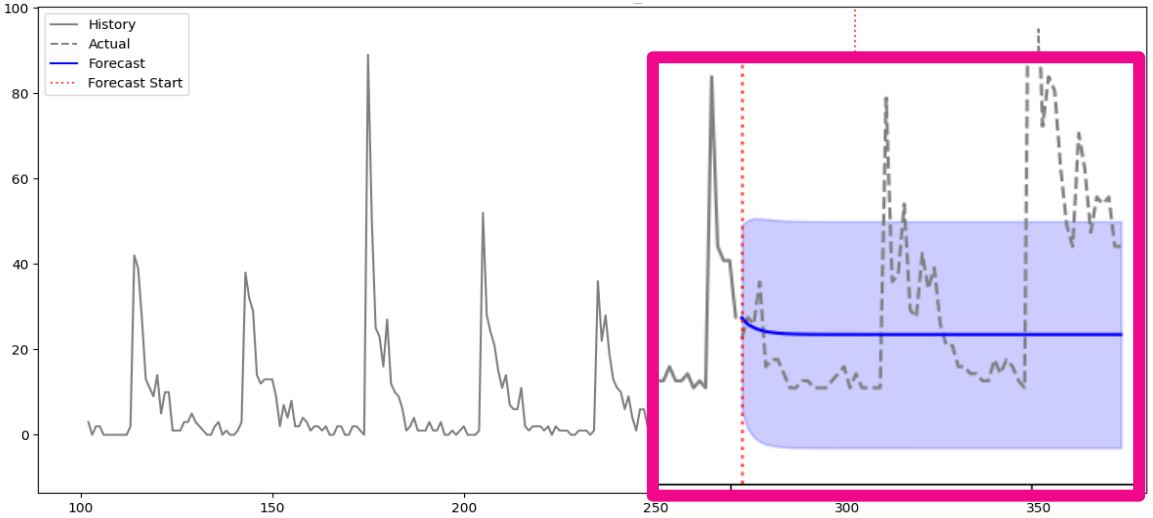

5. 実験3　スパイク予測

実験3　スパイク予測の比較

スパイクに着目し精度を比較

Zスコア=(実測値-平均)/標準偏差

比較モデル
Chronos_bolt+Gate-RAF
SARIMA

性能評価指標	時点
MAE	Spike
	Non-Spike
RMSE	Spike
	Non-Spike

2.0 <= Zスコア

をスパイクと定義

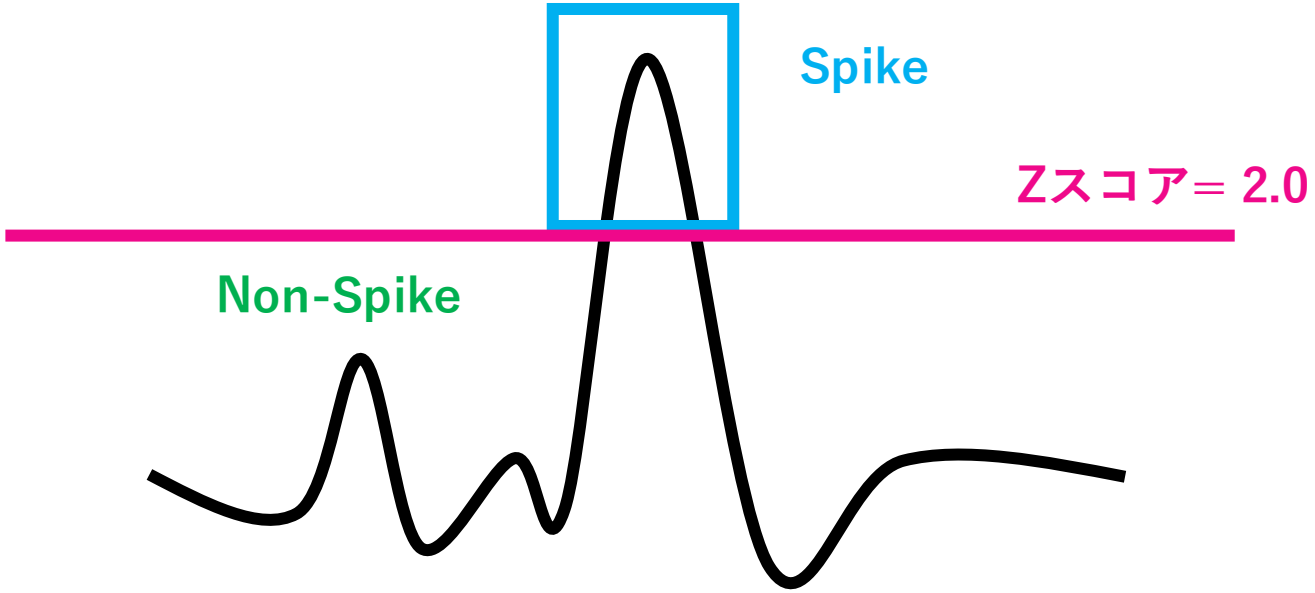

5. 実験3　スパイク予測

実験3　スパイク予測の比較

スパイクに着目し精度を比較

比較モデル
Chronos_bolt+Gate-RAF
SARIMA

性能評価指標	時点
MAE	Spike
	Non-Spike
RMSE	Spike
	Non-Spike

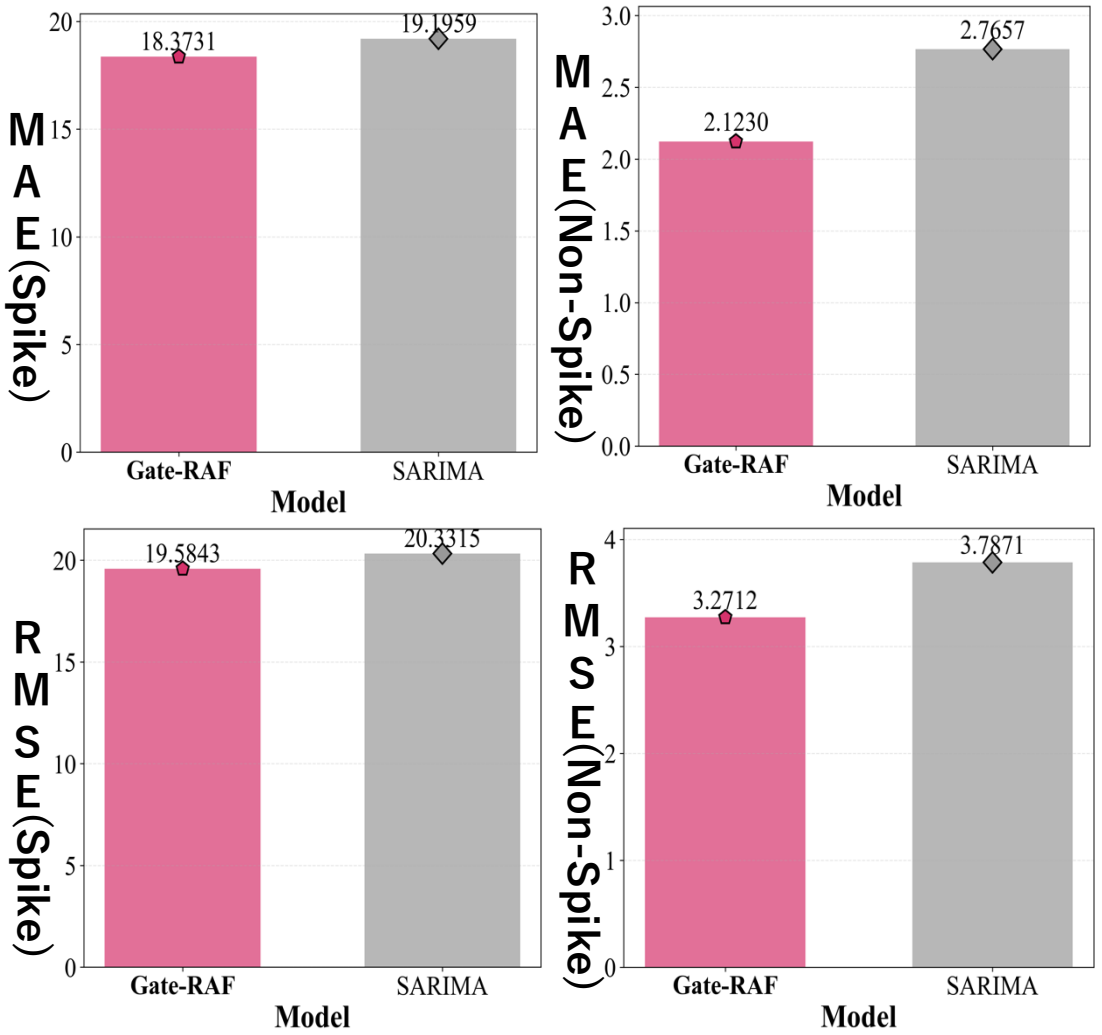

5. 実験3　スパイク予測

実験3　スパイク予測の比較

スパイクに着目し精度を比較

比較モデル
Chronos_bolt+Gate-RAF
SARIMA

性能評価指標	時点
MAE	Spike
	Non-Spike
RMSE	Spike
	Non-Spike

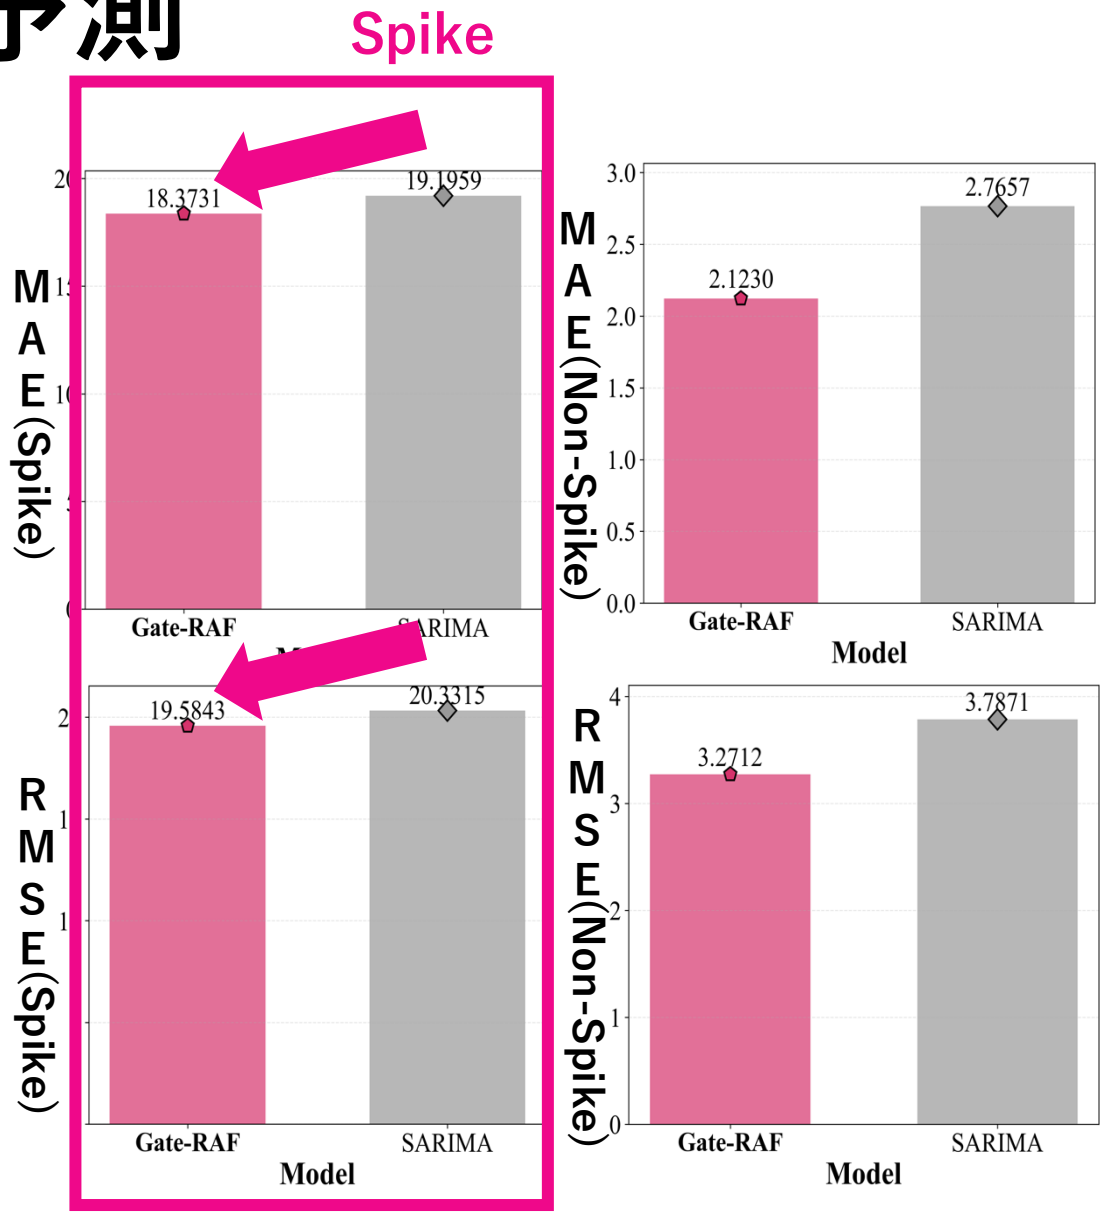

5. 実験3　スパイク予測

実験3　スパイク予測の比較

スパイクに着目し精度を比較

平坦予測

MAE・RMSEともにGate-RAFが優勢

Gate付きRAFは
誤ったスパイク予測をしにくい

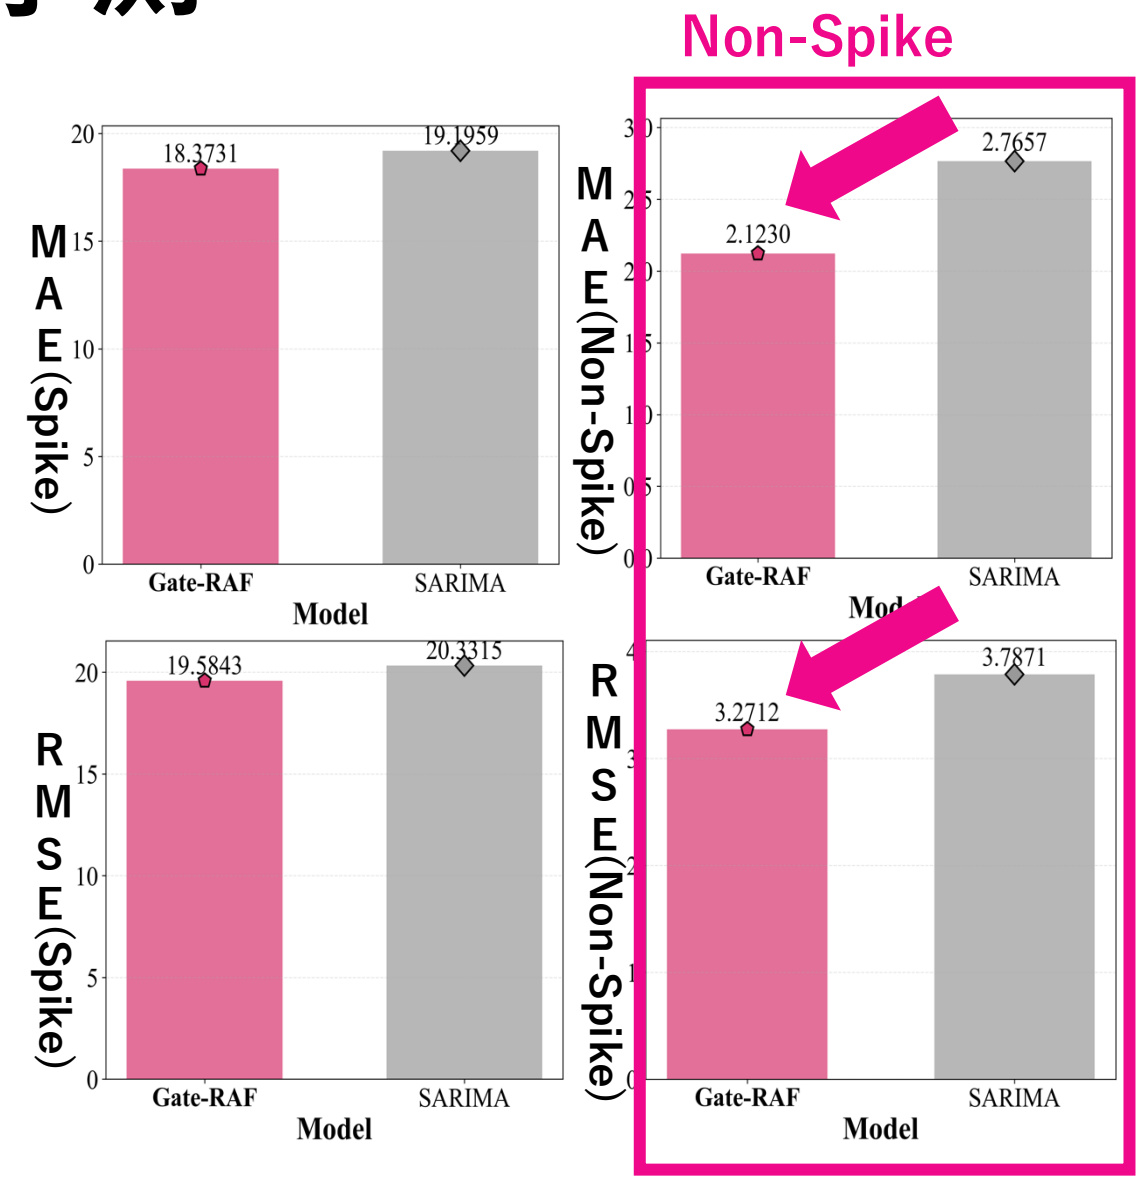

6. 提案手法で期待される返本削減効果

全書店1年間MAEの合計

比較モデル	MAE
Chronos_bolt+Gate-RAF	1,168,813.7
SARIMA	1,512,238.8

返本率(推定)

比較モデル	返本率
Chronos_bolt+Gate-RAF	42.3%
SARIMA	48.7%

$$入荷数 = POS販売冊数 + MAE$$

$$返本率 = \frac{MAE}{入荷数}$$

POS販売冊数は1,592,399冊

1年間に **343,425冊** の返本を削減

返本率が **6.4%** の改善

まとめ

目的

多品種少数生産における“スパイク”の予測

❖ 提案

- RAFによる他書籍の参照
- Gateによる参照の選別

❖ 今後の課題

- Gate機構のCross-Attention化
- Attention等よるモデル内部の解析

参考文献

[1] https://www.jbpa.or.jp/resale/index.html

[2] https://www.e-stat.go.jp/surveyitems/items/400030017

[3] Tire, K., Taga, E. O., Ildiz, M. E., & Oymak, S. (2024). Retrieval augmented time series forecasting. arXiv preprint arXiv:2411.08249.

付録

付録：実験詳細

推論

予測期間	64
入力系列長	128
検索系列長	128
取得検索系列数	3

事後学習

エポック数	1
学習率	1e-5
勾配クリッピング(上限)	1
最適化アルゴリズム	AdamW
学習率変動スケジュール	ウォームアップ
ウォームアップ率	0.1
LoRA・DoRAランク数	16
対象バイパス	Attention層のすべて，FF層の入出力
ドロップアウト率	0.05

付録：実験結果詳細

https://github.com/dmainf/JIMA2025_TCU-mlab

```
実験結果/
├── 実験1/
│   ├── 実験1-1/        # 事後学習手法の比較
│   │   ├── zero-shot/
│   │   ├── LoRA/
│   │   ├── IA3/
│   │   └── DoRA/
│   └── 実験1-2/        # モデルサイズの比較（DoRA + RAF）
│       ├── tiny(DoRA)+RAF/
│       ├── small(DoRA)+RAF/
│       ├── mini(DoRA)+RAF/
│       └── base(DoRA)+RAF/
├── 実験2/              # RAF手法の比較
│   ├── no-RAF/
│   ├── Proto-RAF/
│   └── Gate-RAF/
└── 実験3/              # スパイク・非スパイク日の分析
    ├── Gate-RAF/
    └── SARIMA/
```